

Les réseaux de neurones convolutifs (CNN)

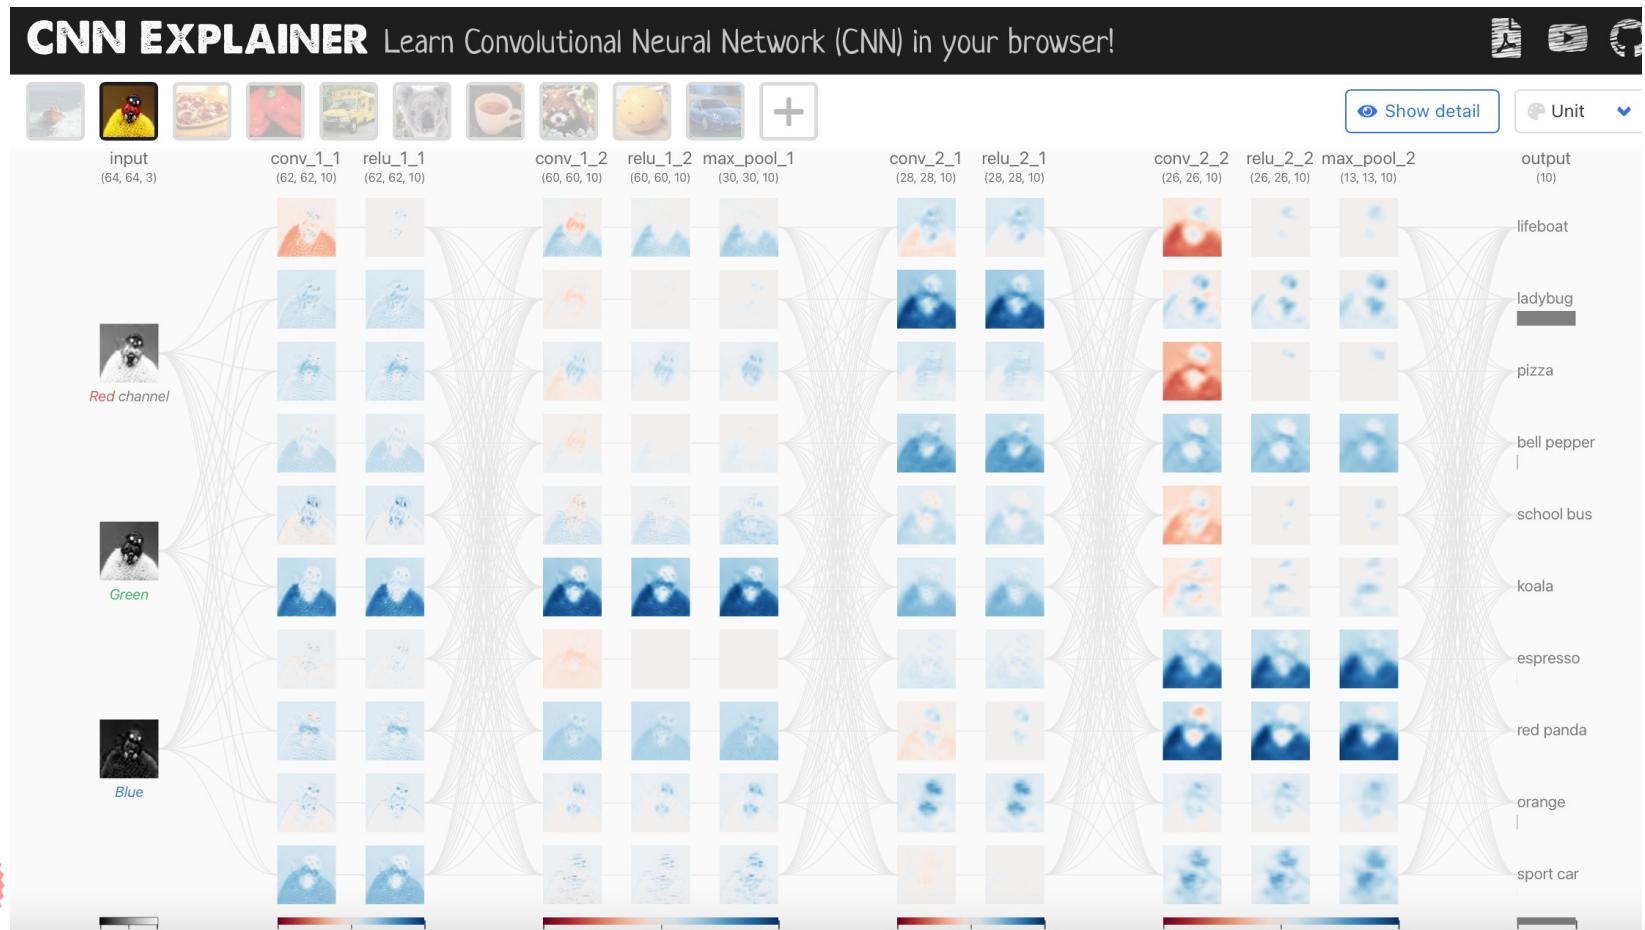
Pascal Poncelet
LIRMM

Pascal.Poncelet@lirmm.fr
<http://www.lirmm.fr/~poncelet>

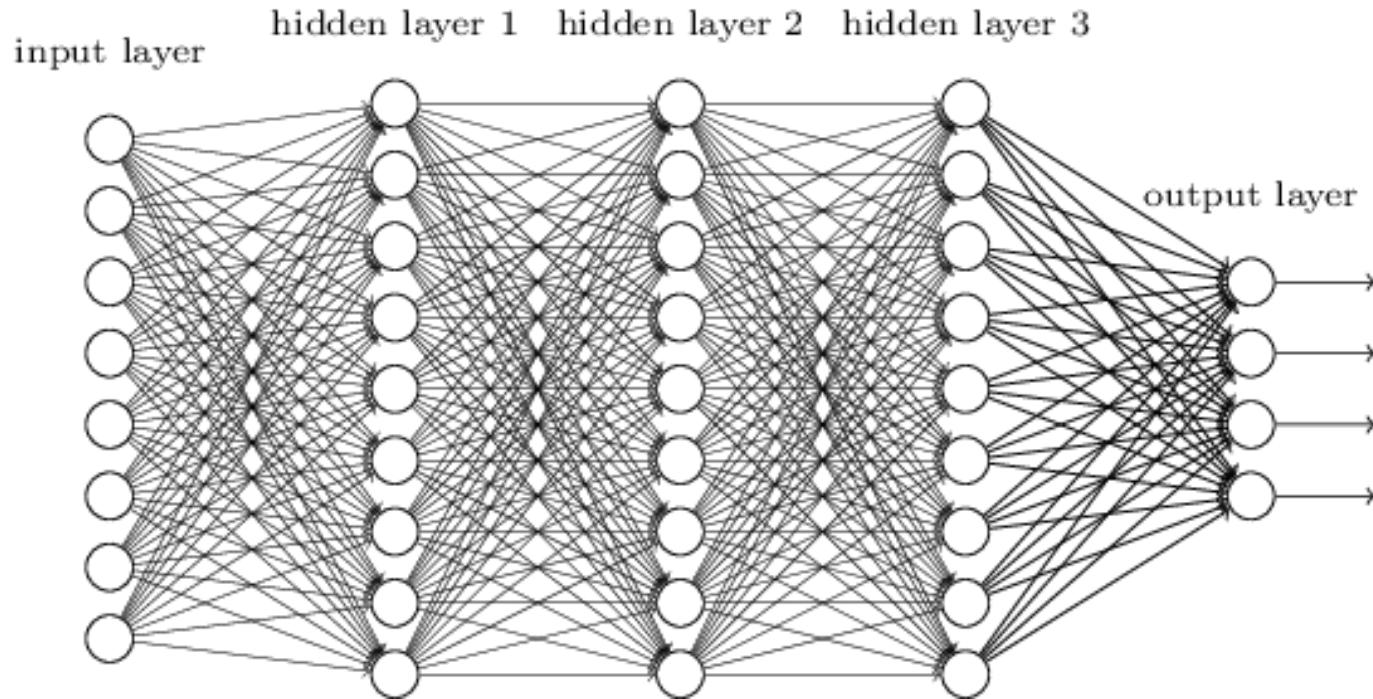


Comprendre ce qui se passe :

- <https://poloclub.github.io/cnn-explainer/>

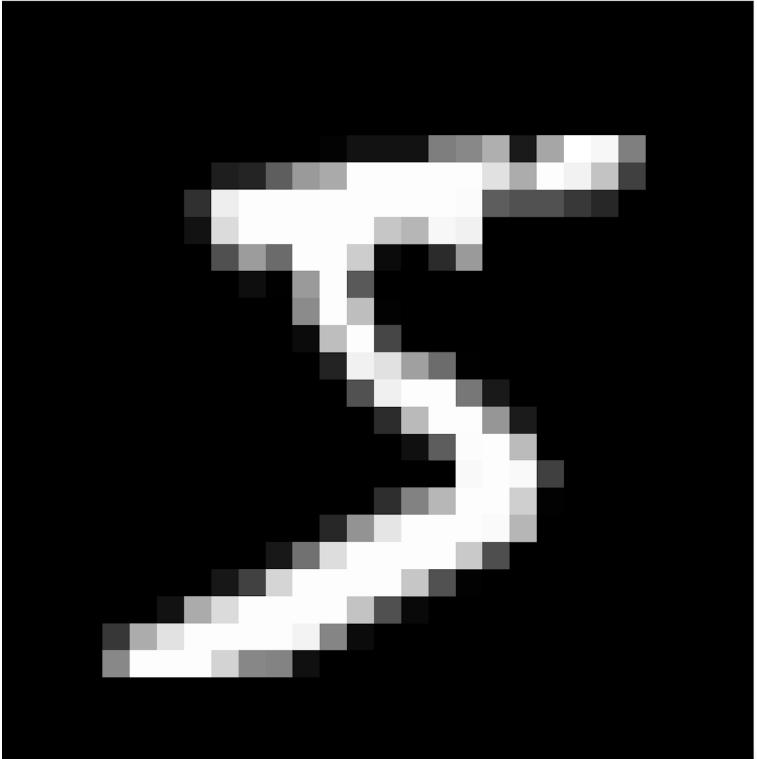


Multi-layer perceptron



- Le modèle peut être trop grand : beaucoup de paramètres à apprendre
- Input layer : « feature selection » ?
- Est-ce qu'on a besoin de tous les arcs ?

Une image



- Un « 5 » - jeu de données MNIST - en gris (valeurs comprises entre 0 et 255)
 - Une image = 28×28 pixels

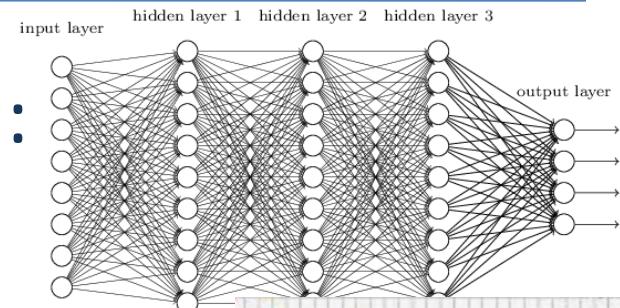
Une image RGB



- Une personne du jeu de données CIFAR 10 en RGB
 - Une image = 32×32 pixels

Avec un MLP

- Conversion pour être compatible :
- 1 image : $32 \times 32 = 1024$
 - Il faut un vecteur de 1024 pour la couche d'entrée
 - Si la première couche cachée possède 100 neurones :
 - $100 \times 1024 = 102400$ paramètres !!!!!



Avec un MLP

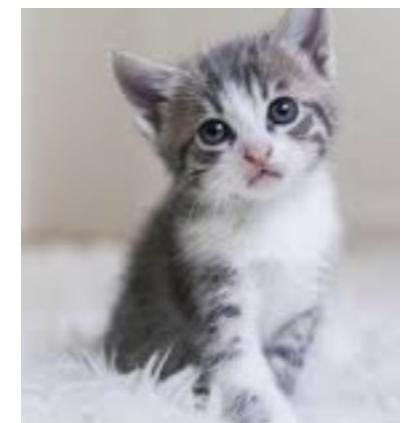
- Sensibilité aux variations



Même image ???

Avec un MLP

- Approche « sac de mots » : pas de corrélation entre les features



Avec un MLP

- Approche « sac de mots » : pas de corrélation entre les features



Apprendre une image ?

- Des « motifs/features» peuvent servir à déterminer une classe

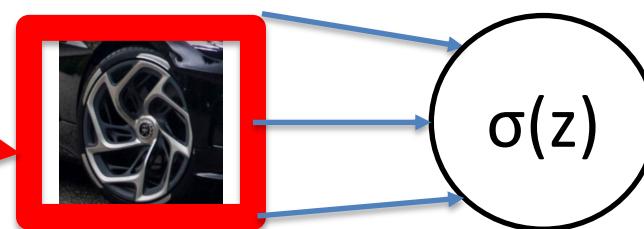


Apprendre une image ?

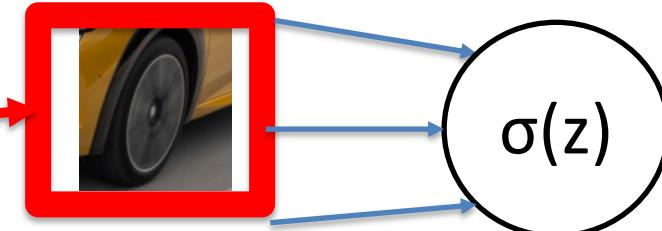
- Des « motifs » existent à différents endroits !
- En fait c'est la même chose : des filtres !



Roue droite

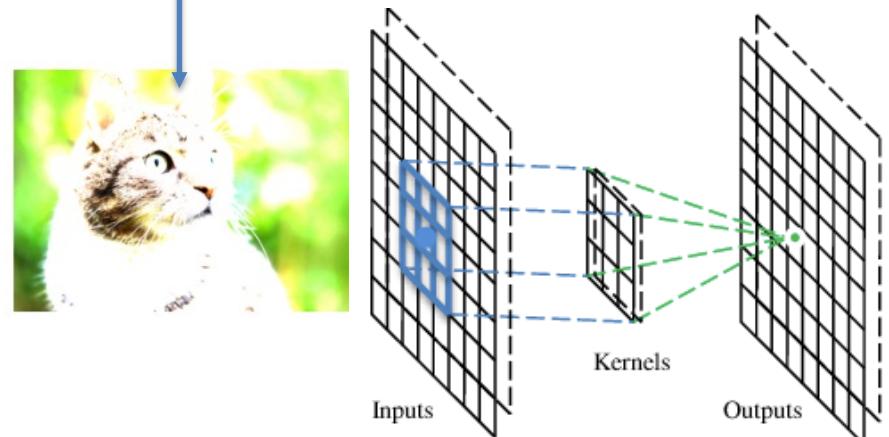
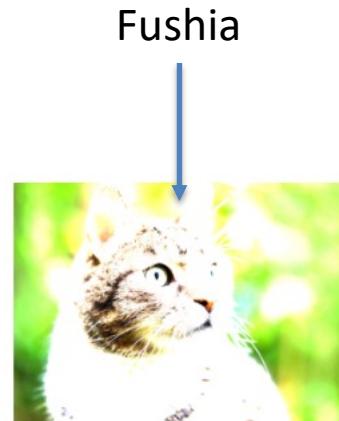
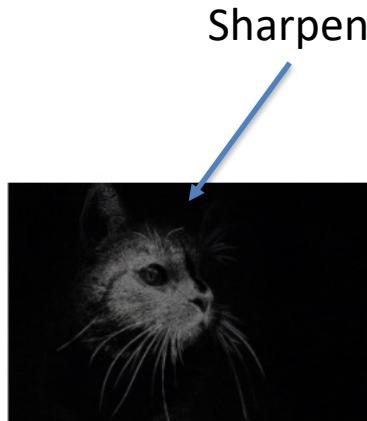


Roue gauche



Une couche de convolution

- La couche de convolution utilise des filtres
- Filtre (Kernel) : matrice qui sert à faire la convolution
- Un filtre est une matrice que l'on applique sur l'image :



Exemple d'application de filtres sur Lena



Original



Sharpen



Edge Detect



“Strong” Edge Detect

- Lena est l'une des photos les plus utilisée depuis 1973 en traitement d'image.
- La photo originale vient de la page centrale du numéro de novembre 1972 de Playboy

Une démonstration de filtres : <https://setosa.io/ev/image-kernels/>

Principe d'une convolution

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

1	-1	-1
-1	1	-1
-1	-1	1

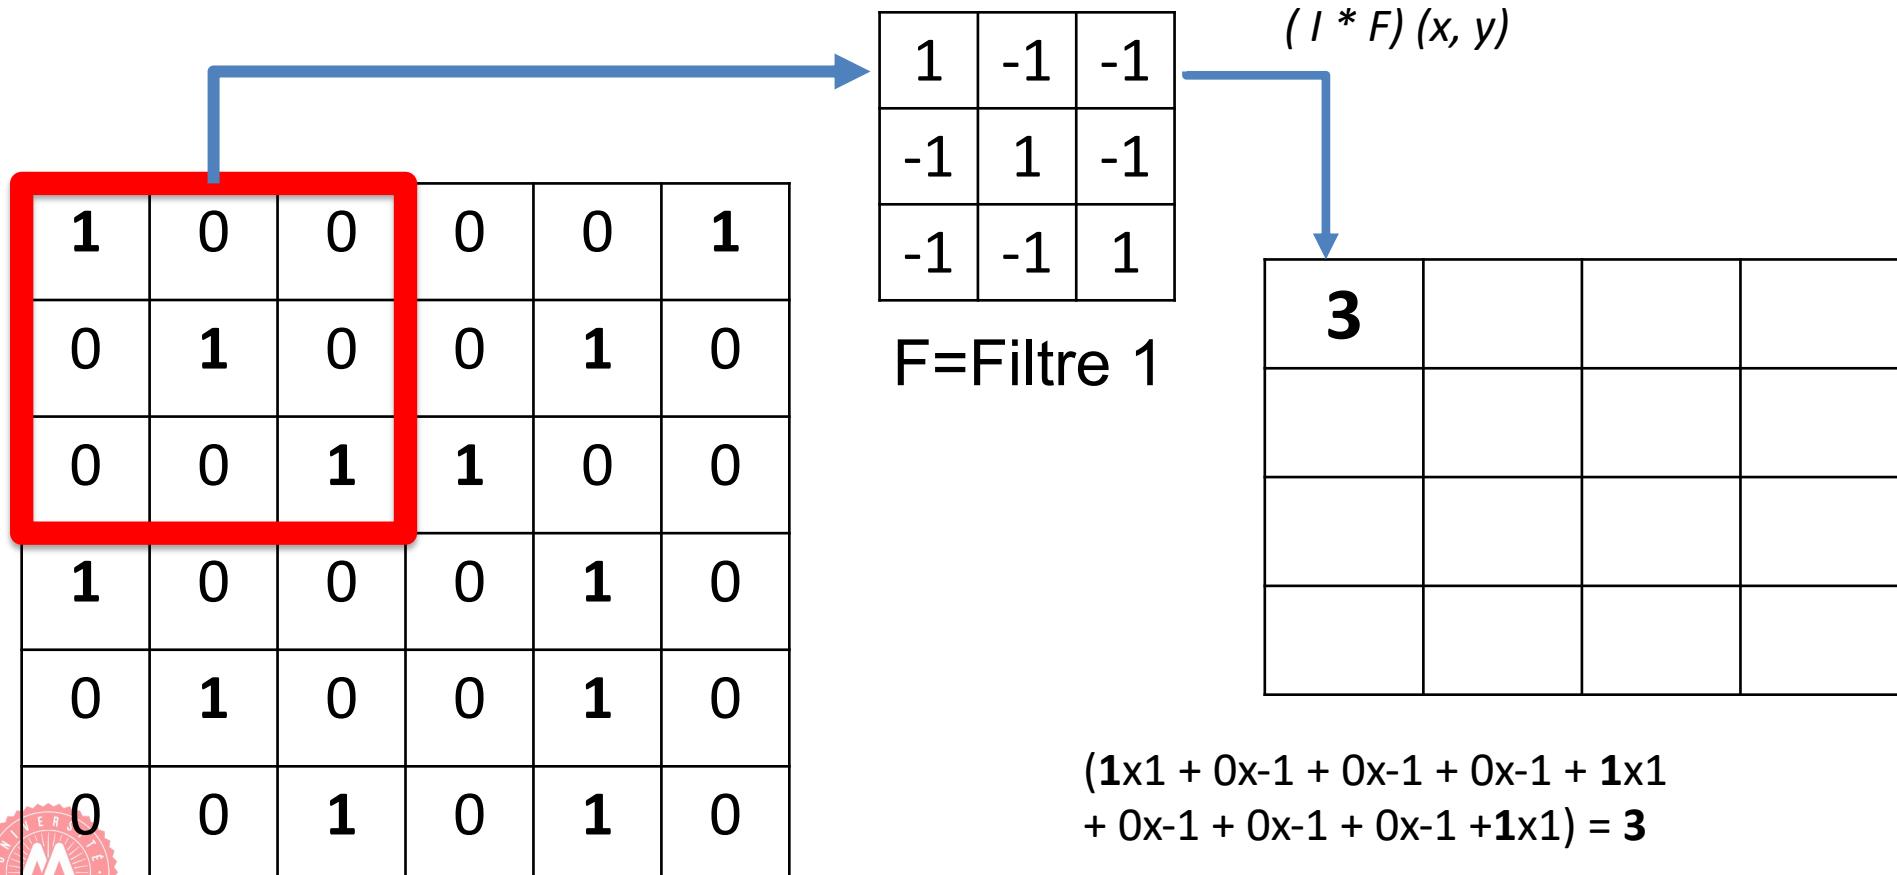
Filtre 1

Image : matrice 6×6

Principe d'une convolution

$$(I * F)(i, j) = (F * I)(i, j) = \sum_m \sum_n F(m, n) I(i - m, j - n)$$

commutative



Principe d'une convolution

Stride = 1

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

1	-1	-1
-1	1	-1
-1	-1	1

Filtre 1

3	-1		

Principe d'une convolution

Stride = 1

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

1	-1	-1
-1	1	-1
-1	-1	1

Filtre 1

3	-1	-3	

Principe d'une convolution

Stride = 1

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

1	-1	-1
-1	1	-1
-1	-1	1

3	-1	-3	-1
-3			

Principe d'une convolution

Stride = 1

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

1	-1	-1
-1	1	-1
-1	-1	1

Filtre 1

3	-1	-3	-1
-3	1	0	-3
-3	-3	0	1
3	-2	-2	-1

Principe d'une convolution

Stride = 2

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

1	-1	-1
-1	1	-1
-1	-1	1

3	-3	...	
...			

Plusieurs filtres : répéter l'opération

Stride = 1

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

1	-1	-1
-1	1	-1
-1	-1	1

Filtre 1

-1	1	-1
-1	1	-1
-1	1	-1

Filtre 2

3	-1	-3	-1
-3	1	-1	-1
-3	-3
3	-2
-1	0	-4	3

2 images (4 x 4) formant une matrice de 2 x 4 x 4

Ici 2 feature maps

Padding

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

- Le pixel (bleu) dans le coin ne sera vu qu'une seule fois
- Les pixels du milieu (rouge) seront vus plusieurs fois :
 - plus d'informations sur les pixels du milieu !
 - Diminution des sorties
 - Perte d'informations sur les coins de l'image

Padding

- Couche supplémentaire ajoutée à la bordure de l'image

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

Image : matrice 6 x 6

0	0	0	0	0	0	0	0
0	1	0	0	0	0	1	0
0	0	1	0	0	1	0	0
0	0	0	1	1	0	0	0
0	1	0	0	0	1	0	0
0	0	1	0	0	1	0	0
0	0	0	1	0	1	0	0
0	0	0	0	0	0	0	0

Image : matrice 8 x 8

Padding

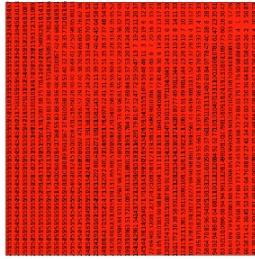
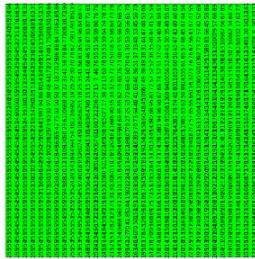
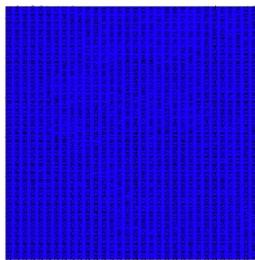
0	0	0	0	0	0	0	0
0	1	0	0	0	0	1	0
0	0	1	0	0	1	0	0
0	0	0	1	1	0	0	0
0	1	0	0	0	1	0	0
0	0	1	0	0	1	0	0
0	0	0	1	0	1	0	0
0	0	0	0	0	0	0	0

1	-1	-1
-1	1	-1
-1	-1	1

2
...
...
...

Image couleur : même principe

- 3 canaux :



1	-1	-1
-1	1	-1
-1	-1	1

Filtre 1

-1	1	-1
-1	1	-1
-1	1	-1

Filtre 2

1	0	0	0	0	1
0	1	0	0	0	1
0	0	1	0	0	0
1	0	0	1	0	0
0	1	1	0	0	0
1	0	0	0	1	0
0	0	1	1	0	0
1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	0	0	0
0	0	0	1	0	0
0	0	1	0	1	0

Convolution : pour résumer

Chaque filtre permet de détecter un motif.

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

1	-1	-1
-1	1	-1
-1	-1	1

Filtre 1

-1	1	-1
-1	1	-1
-1	1	-1

Filtre 2

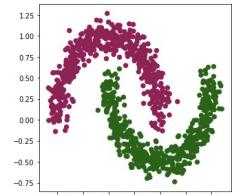
.

.

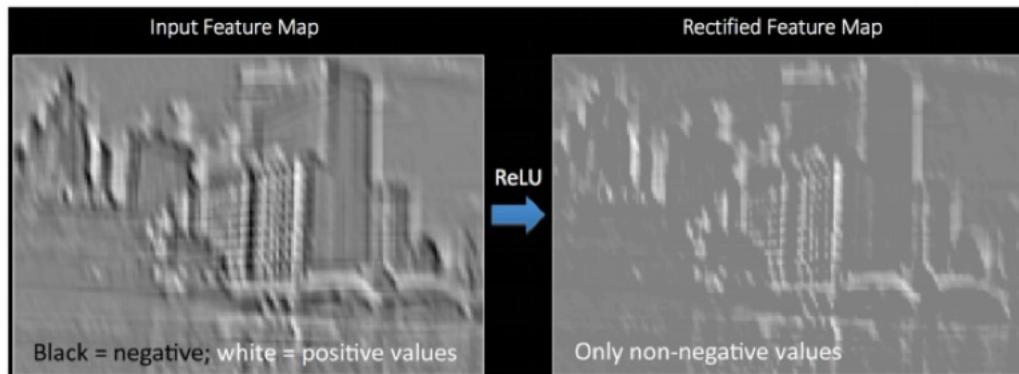
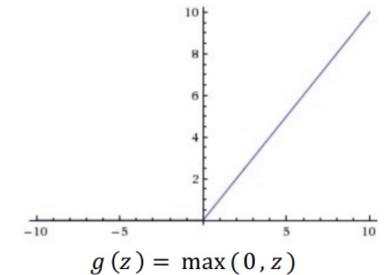
Les filtres sont dérivables, leur valeur correspondent aux paramètres à apprendre

Une couche de fonctions d'activation

- Introduction de non linéarité
- Techniquement pas une couche car il n'y a pas de paramètres à apprendre
- Généralement : Relu ou Leaky Relu

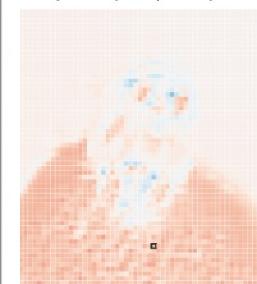


Rectified Linear Unit (ReLU)



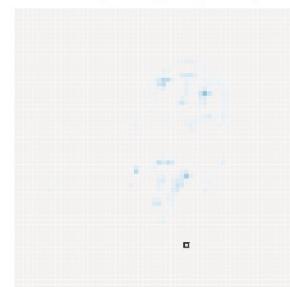
Black = negative; white = positive values

Input (62, 62)



$$\max(\boxed{0} , \boxed{-0.7}) = \boxed{0}$$

Output (62, 62)



Exemple

- Sur la sortie précédente

3	-1	-3	-1
-3	1	0	-3
-3	-3	0	1
3	-2	-2	-1

Feature map



RELU

3	0	0	0
0	1	0	0
0	0	0	1
3	0	0	0

Activation map

Convolution vs fully connected

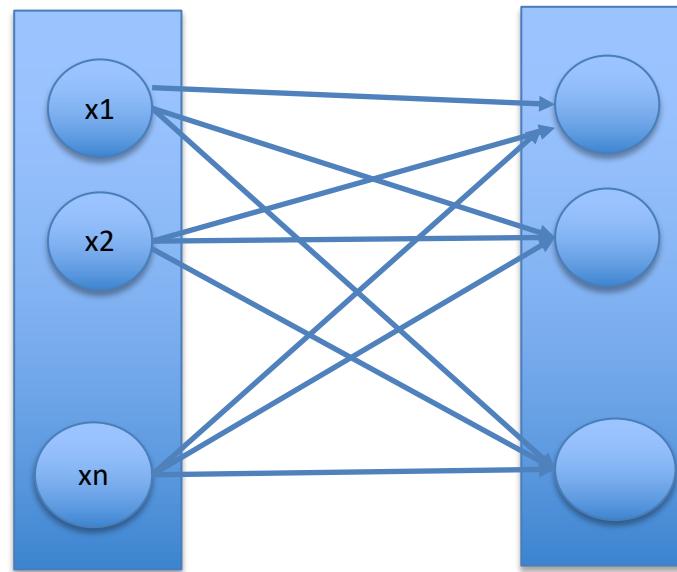
1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0

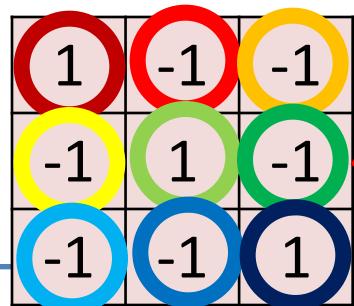
1	-1	-1
-1	1	-1
-1	-1	1

Filtre 1

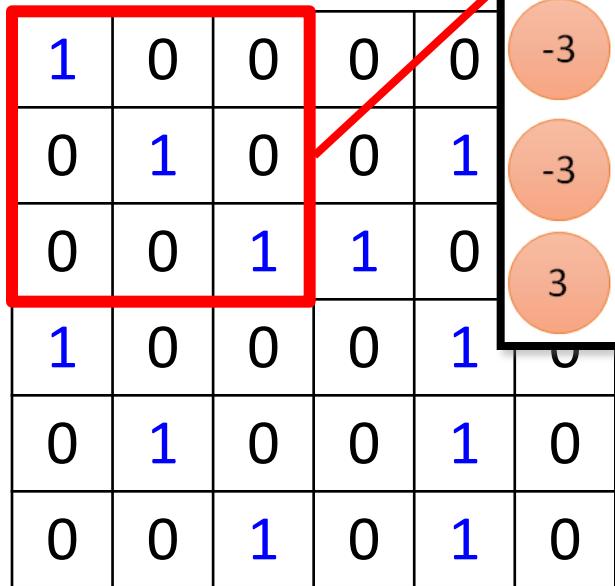
3	-1	-3	-1
-3	1	0	-3
-3	-3	0	1
3	-2	-2	-1

1	0	0	0	0	1
0	1	0	0	1	0
0	0	1	1	0	0
1	0	0	0	1	0
0	1	0	0	1	0
0	0	1	0	1	0



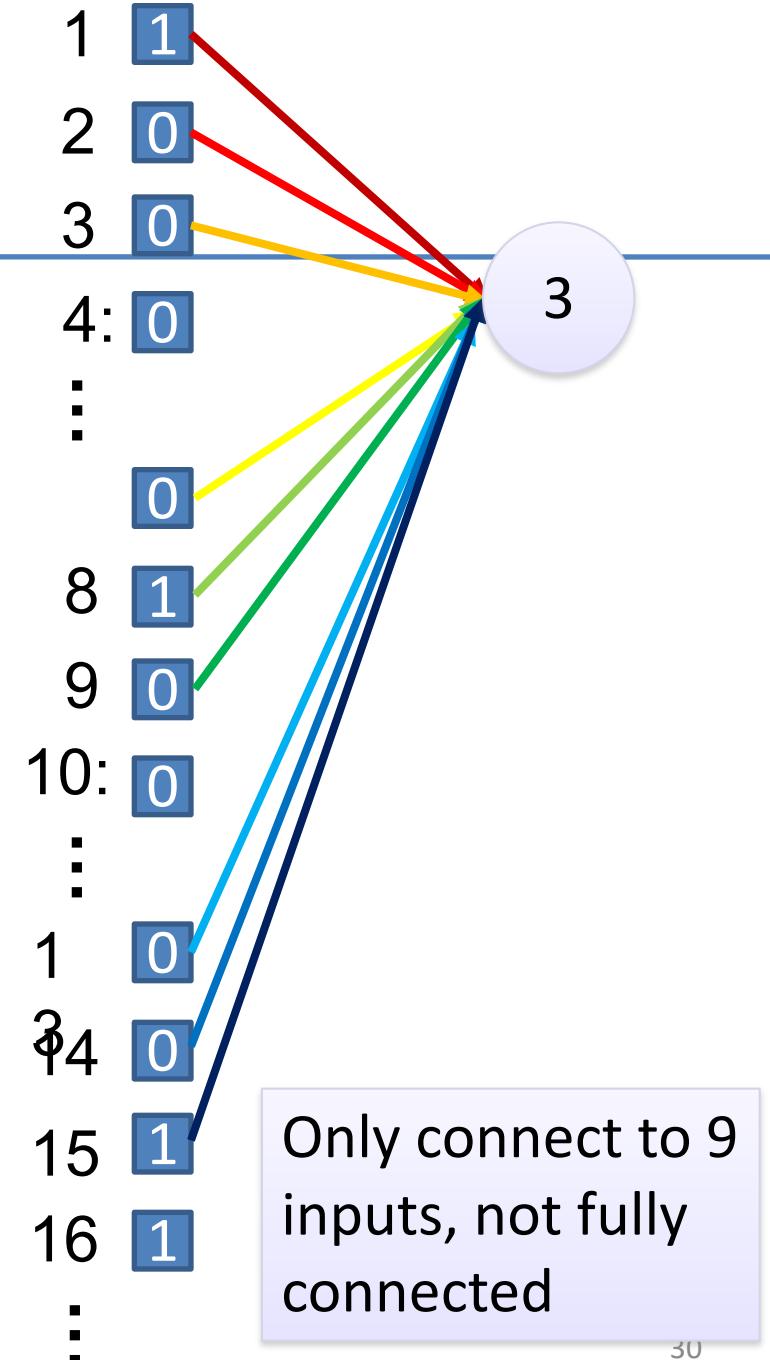
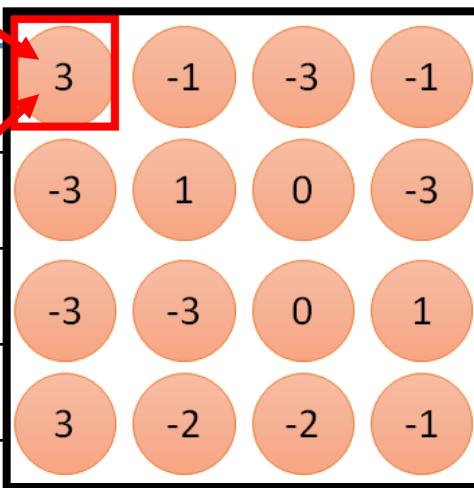


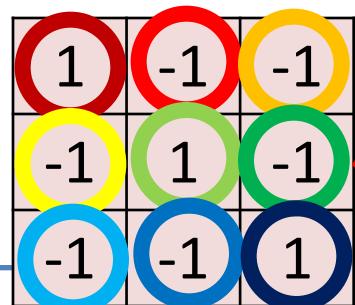
Filter 1



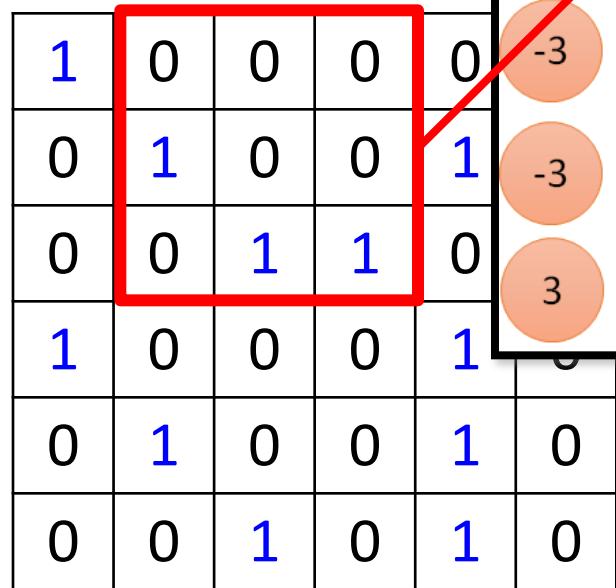
6×6 image

fewer parameters!





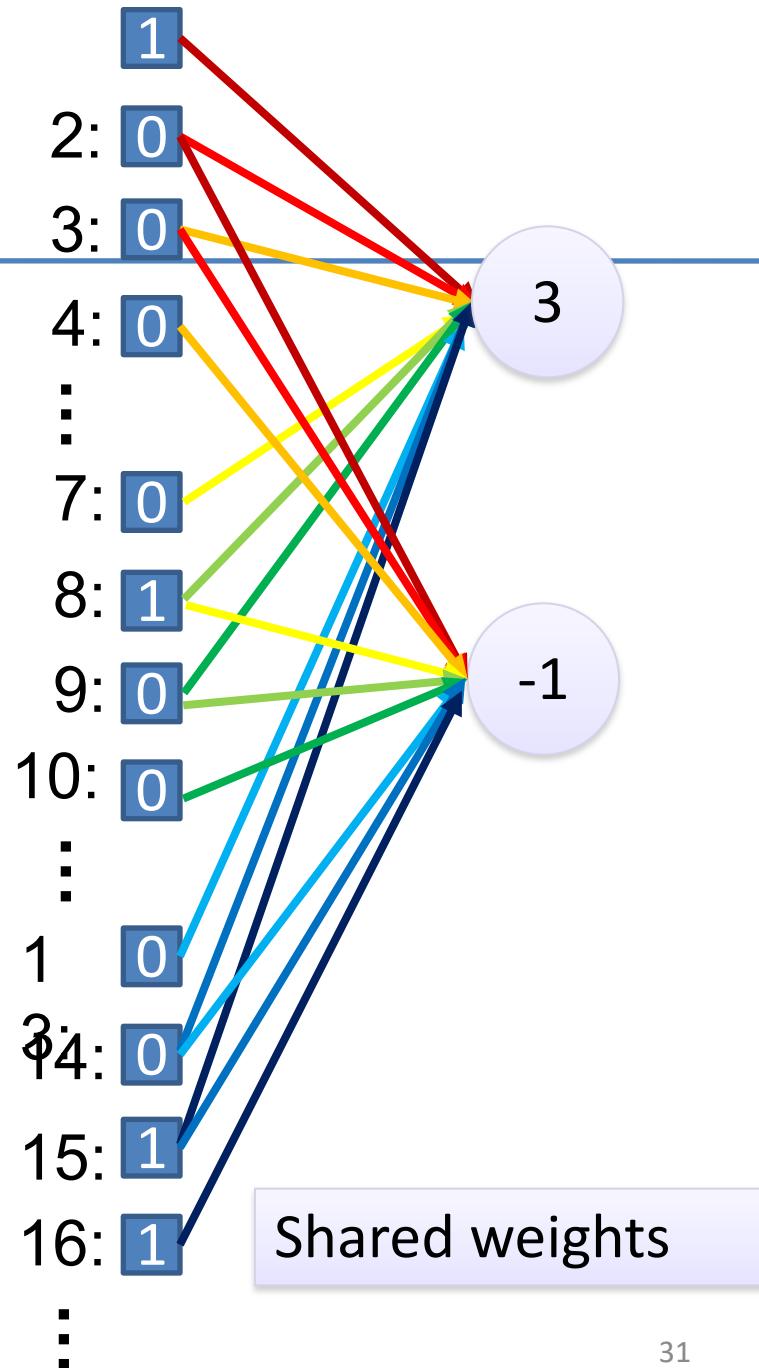
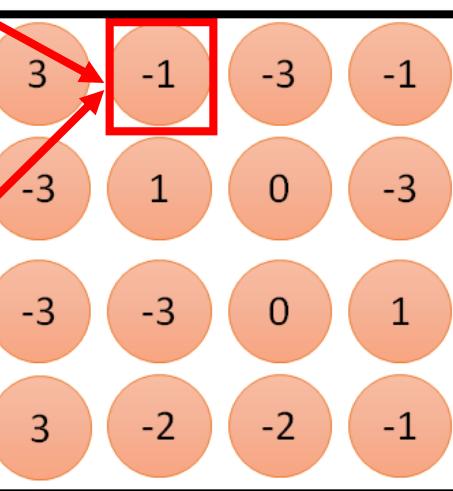
Filter 1



6×6 image

Fewer parameters

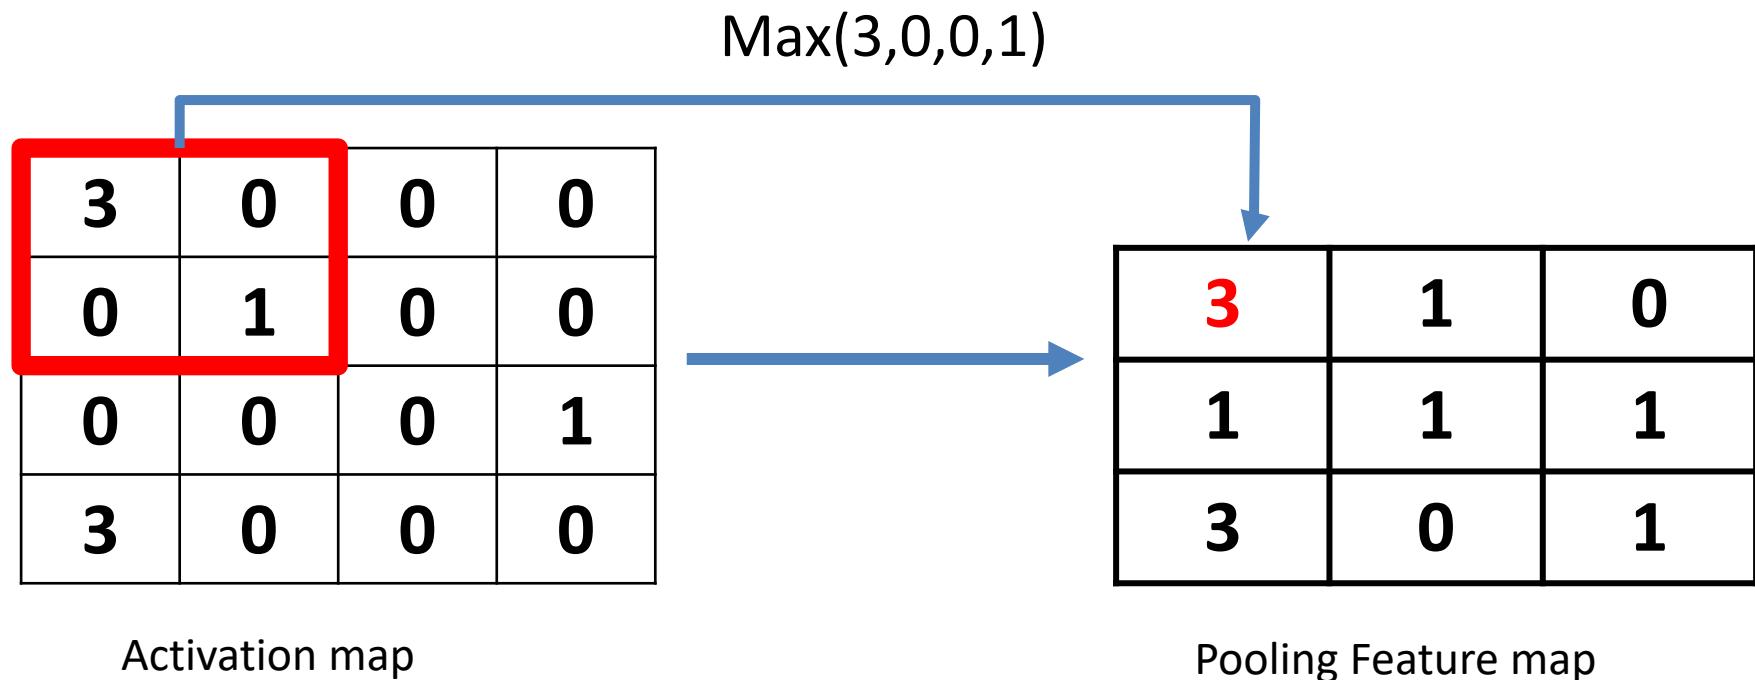
Even fewer parameters



Réduire la taille : pooling

- Objectifs :
 - Obtenir un représentation plus petite (empêche le surapprentissage en éliminant les données inutiles et gain en vitesse de calcul)
 - Réduire encore la taille de l'image !
 - Voir dilatation ...

Réduire la taille : Pooling



Max pooling avec un filtre 2x2 et un stride de 1

Réduire la taille : pooling

Encore plus petit : 75% de réduction

$$\text{Max}(3,0,0,1)$$

3	0	0	0
0	1	0	0
0	0	0	1
3	0	0	0

Activation map

3	0
3	1

Pooling Feature map

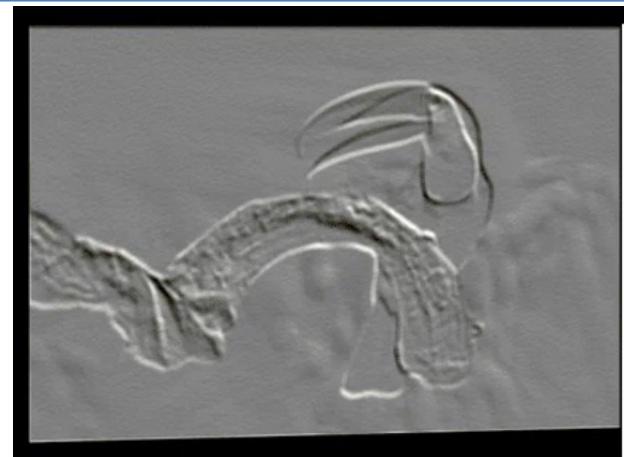
Max pooling avec un filtre 2x2 et un stride de 2

Généralement utilisation d'un stride de 2 pour le pooling.
3 pour les images > 200 pixels

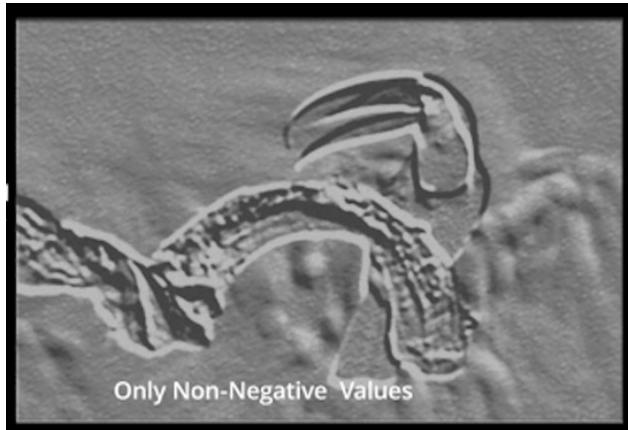
Les étapes en résumé



Image originale



Feature map



Only Non-Negative Values

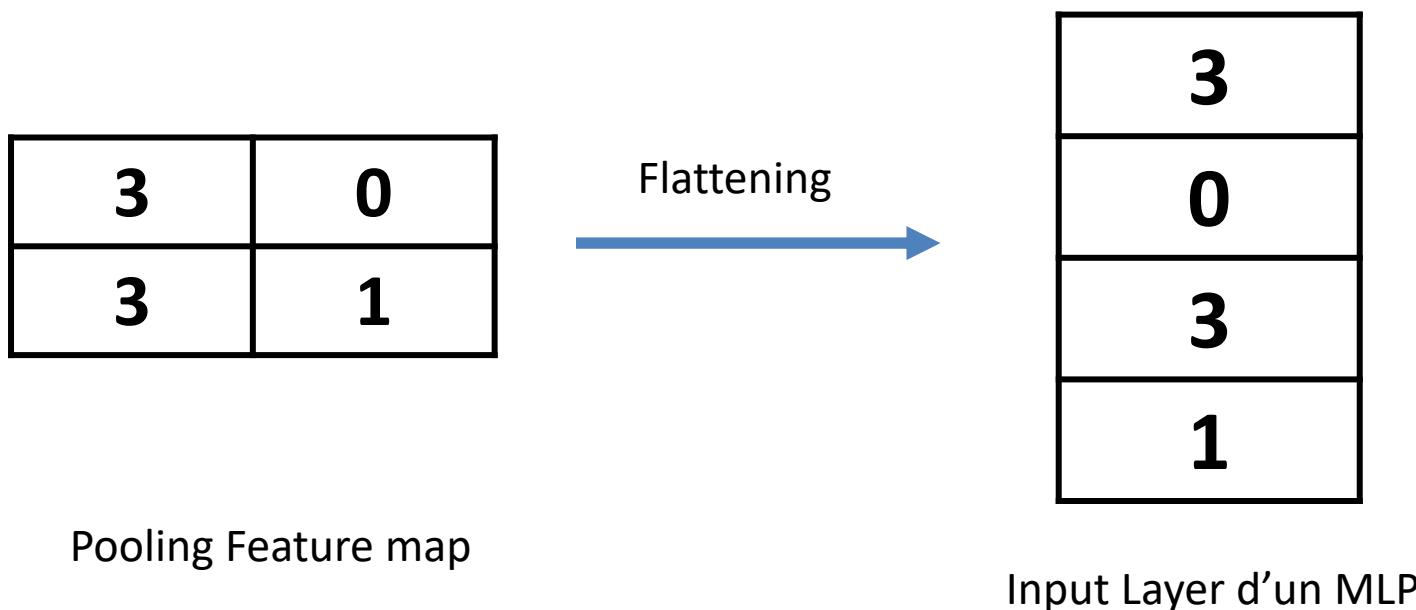
Activation map



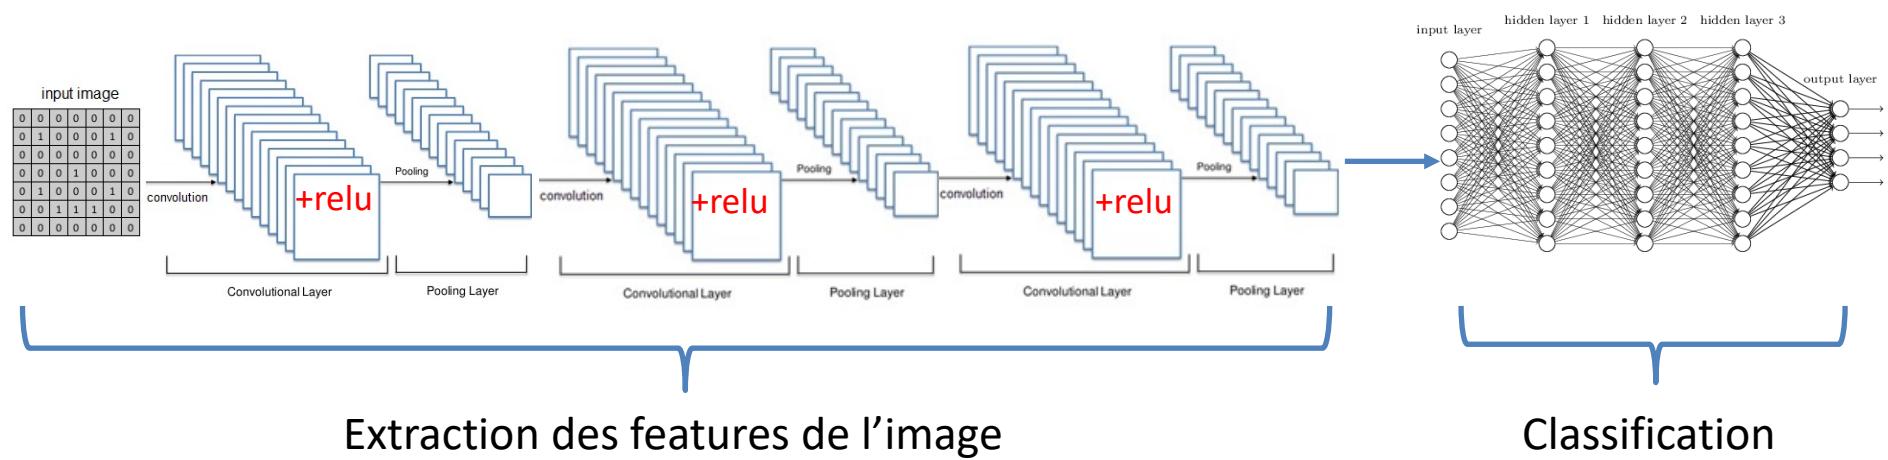
Pooling feature map

Couche Flatten

- Objectif : transformer la matrice de sortie en vecteur pour servir d'entrée à un MLP

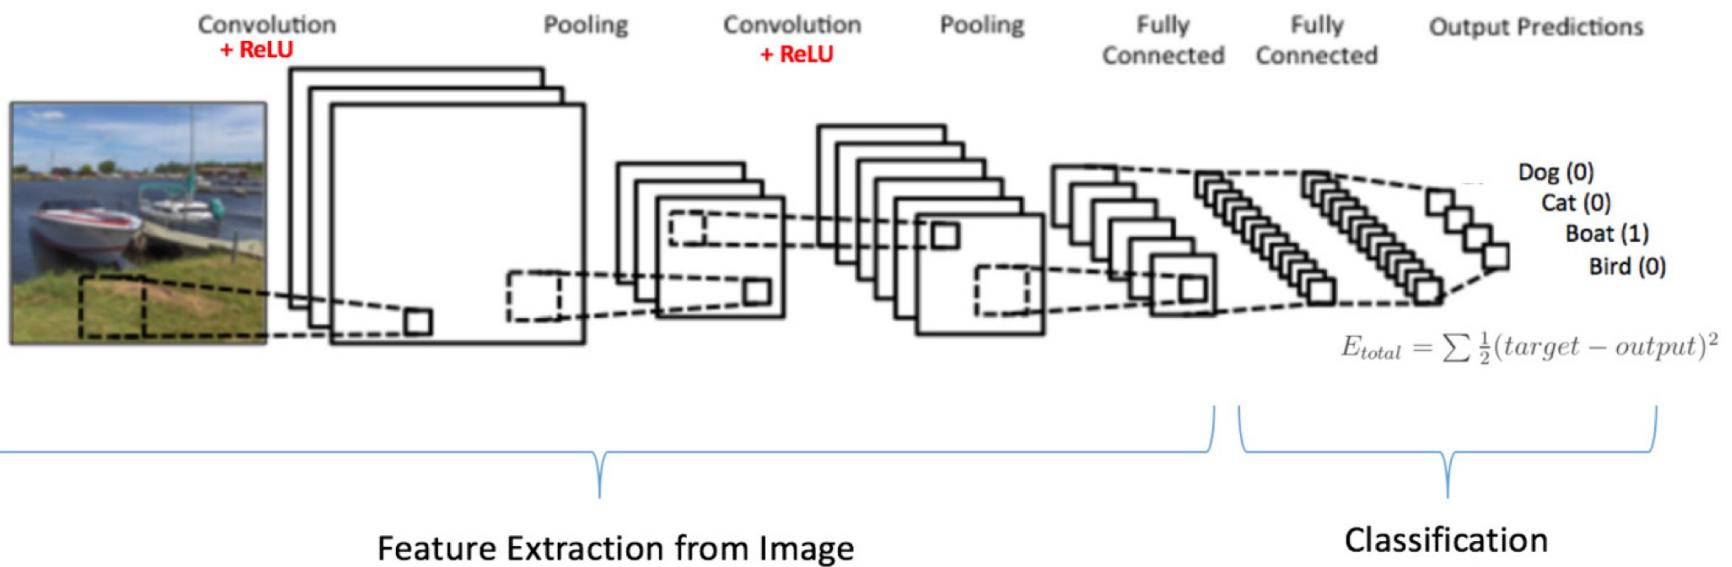


Architecture d'un CNN



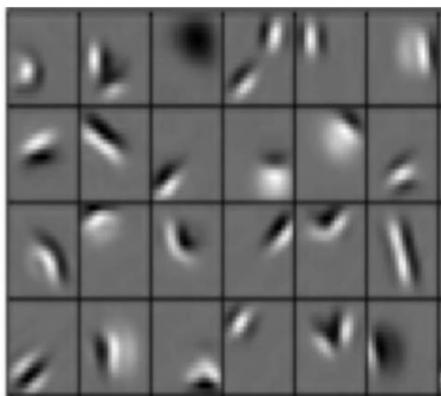
INPUT => CONV => RELU => POOL => CONV => RELU => POOL => CONV => RELU => FC => SOFTMAX

Architecture d'un CNN



Rôle des différentes convolution

Low level features



Edges, dark spots

Conv Layer 1

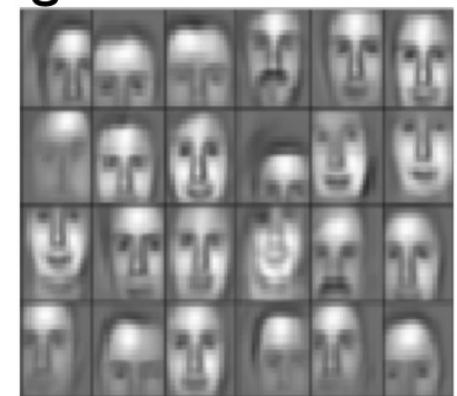
Mid level features



Eyes, ears, nose

Conv Layer 2

High level features



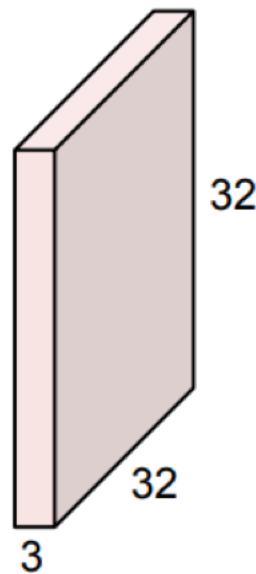
Facial structure

Conv Layer 3

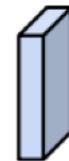
Source: Lee+ ICML2009

Taille des layers

32x32x3 image

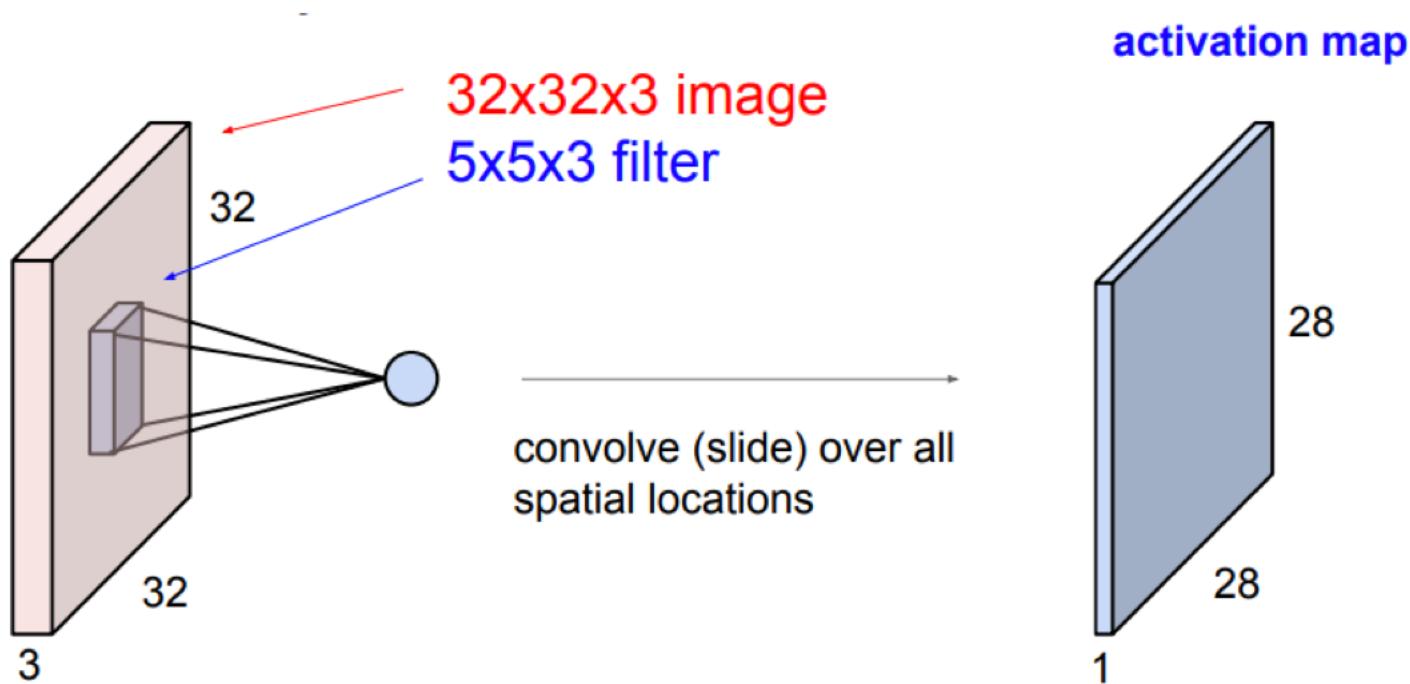


5x5x3 filter



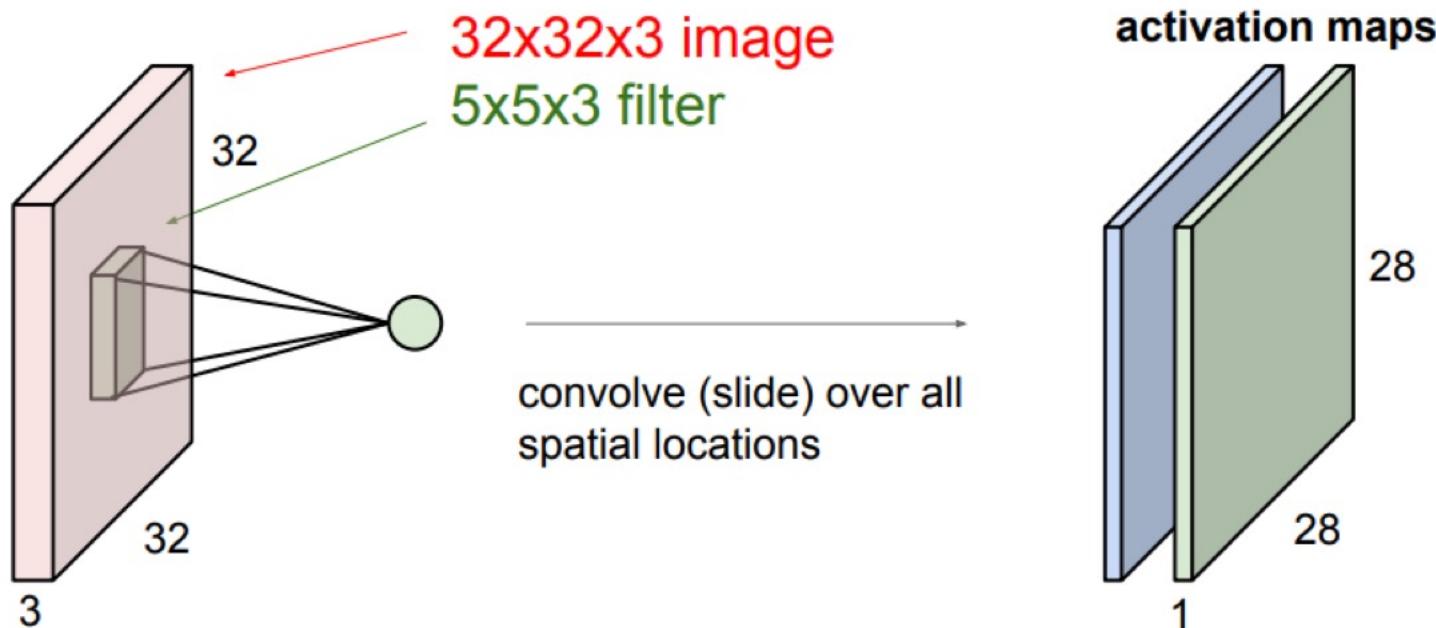
Faire une convolution du filtre sur l'image

Taille des layers



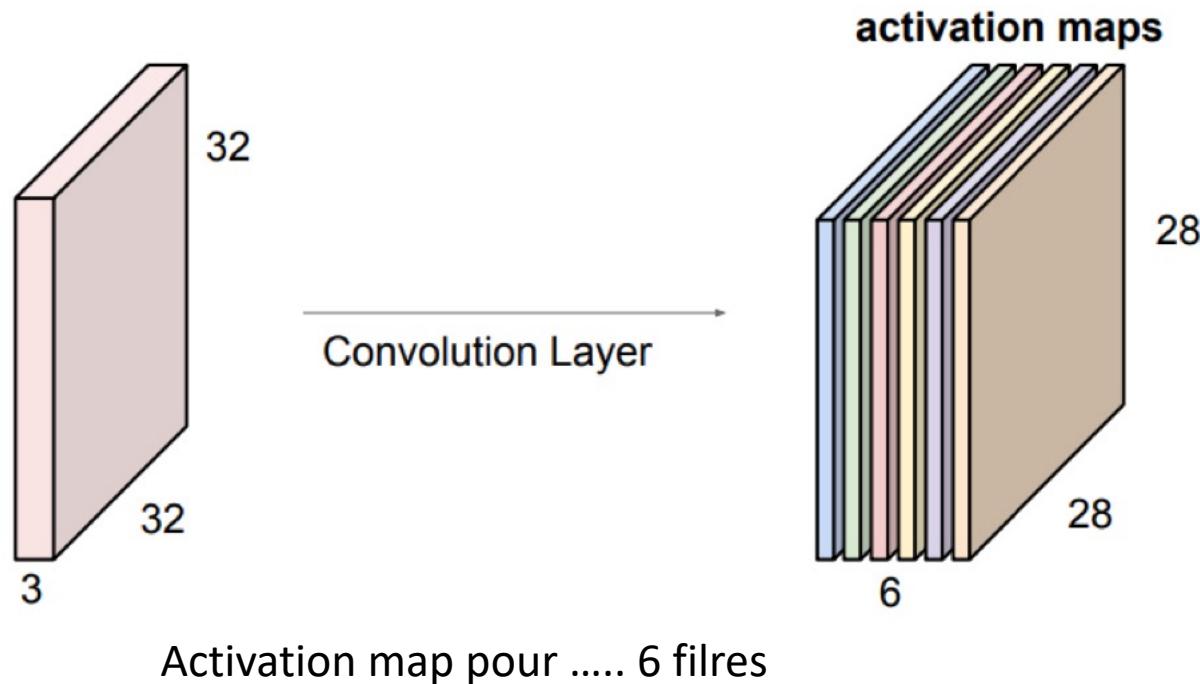
Activation map pour le filtre 1

Taille des layers



Activation map pour le filtre 2

Taille des layers



Les activations maps sont empilées pour créer une nouvelle image de taille 28x28x6

Taille de sortie de la convolution

Avec une image de :

W₁ x H₁ x D₁ (D₁ = nombre de canaux),
K, le nombre de filtres,
F, la taille du filtre,
S, le stride et P, le nombre de zéro du padding

La sortie de la convolution est :

$$W_2 = (W_1 - F + 2 \times P) / S + 1$$

$$H_2 = (H_1 - F + 2 \times P) / S + 1$$

$$D_2 : K$$

Pour une image 255x255 avec 64 canaux, avec 40 filtres de taille 5x5, sans padding et stride=1 (défaut) :

$$W_2 = (128 - 5 + 2 \times 0) / 1 + 1 = 124$$

$$H_2 = (128 - 5 + 2 \times 0) / 1 + 1 = 124$$

$$D_2 = 40$$

Outputshape (124, 124, 40)



Filtre, stride et padding : carrés ?

- Un filtre (resp. padding) n'est pas nécessairement une matrice carrée ... pour obtenir la taille il faut redéfinir :

1 image = $W_1 \times H_1 \times D_1$

Nombre de filtres : K

Taille du filtre : K_W, K_H

Taille du stride : S_W, S_H

Taille du padding :

Padding hauteur haut (P_{H1})

Padding hauteur bas (P_{H2})

Padding largeur à gauche (P_{W1})

Padding margeur à droite (P_{W2})

Filtre, stride et padding : carrés ?

$$W_2 = (W_1 + P_{_W} + PW_2 - KW) / SW + 1$$

$$H_2 = (H_1 + P_{_H} + PH_2 - KH) / SH + 1$$

$$D_2 = K$$

- Pour une image couleur de 255x255 avec 30 filtres de taille 7, 128, un stride de 3x4 et et un padding de 2 (e.g. [2, 2, 2, 2]) :

$$W_2 = (255 + 2 + 2 - 7) / 4 + 1 = 64$$

$$H_2 = (255 + 2 + 2 - 7) / 3 + 1 = 85$$

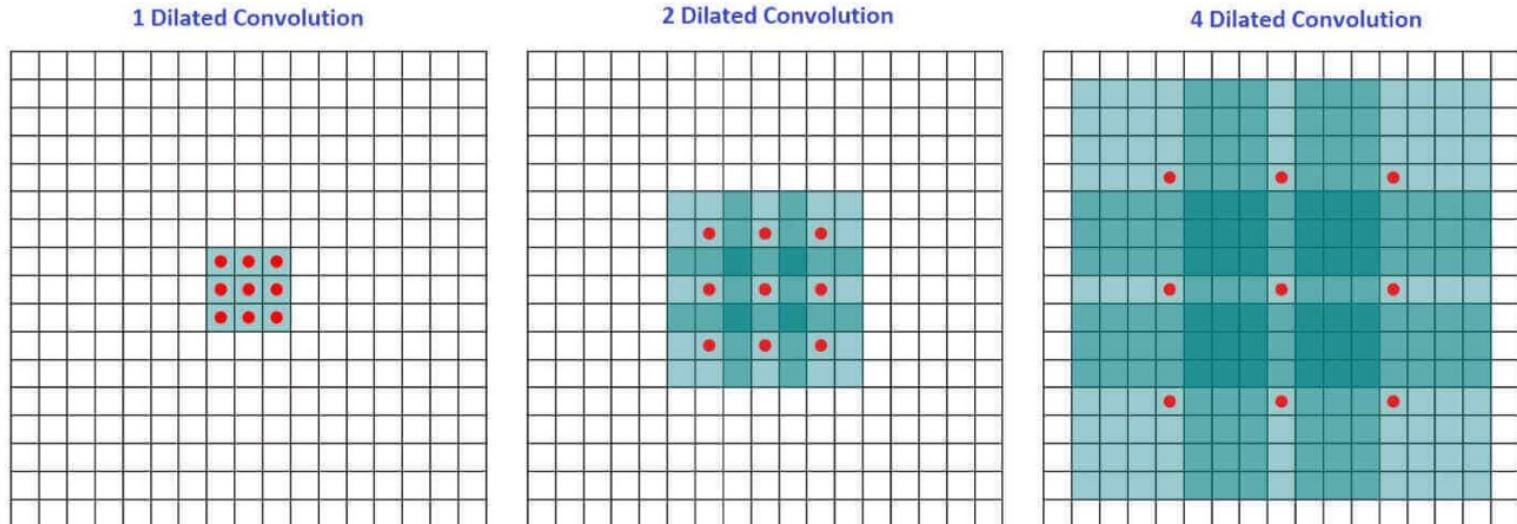
$$D_2 = 30$$

Outputshape (85, 64, 30)



Dilatation

- La dilatation permet de sauter certains points lors de la convolution
- Utilisation d'un paramètre ($l = \text{dilatation rate}$) qui permet de dire combien on saute de pixels



Dilatation

- Elle permet d'étendre la zone de l'image d'entrée couverte sans pooling.
- Avoir un champ de vision plus large au moindre coût
- Pas de perte de résolution de l'image de sortie : il s'agit d'une extension



Un mot sur la backpropagation

$$\begin{matrix} O_{11} & O_{12} \\ O_{21} & O_{22} \end{matrix} = \text{Convolution} \left(\begin{matrix} X_{11} & X_{12} & X_{13} \\ X_{21} & X_{22} & X_{23} \\ X_{31} & X_{32} & X_{33} \end{matrix}, \begin{matrix} F_{11} & F_{12} \\ F_{21} & F_{22} \end{matrix} \right)$$

$$O_{11} = F_{11}X_{11} + F_{12}X_{12} + F_{21}X_{21} + F_{22}X_{22}$$

$$O_{12} = F_{11}X_{12} + F_{12}X_{13} + F_{21}X_{22} + F_{22}X_{23}$$

$$O_{21} = F_{11}X_{21} + F_{12}X_{22} + F_{21}X_{31} + F_{22}X_{32}$$

$$O_{22} = F_{11}X_{22} + F_{12}X_{23} + F_{21}X_{32} + F_{22}X_{33}$$

$$\begin{matrix} \partial E / \partial F_{11} & \partial E / \partial F_{12} \\ \partial E / \partial F_{21} & \partial E / \partial F_{22} \end{matrix} = \text{Convolution} \left(\begin{matrix} X_{11} & X_{12} & X_{13} \\ X_{21} & X_{22} & X_{23} \\ X_{31} & X_{32} & X_{33} \end{matrix}, \begin{matrix} \partial E / \partial O_{11} & \partial E / \partial O_{12} \\ \partial E / \partial O_{21} & \partial E / \partial O_{22} \end{matrix} \right)$$

<https://medium.com/@2017csm1006/>

forward-and-backpropagation-in-convolutional-neural-network-4dfa96d7b37e

En pratique

```
model = Sequential()  
# Convolution and pooling  
model.add(Conv2D(filters=32,  
                  kernel_size=(3, 3),  
                  activation='relu',  
                  padding="same",  
                  input_shape=(28, 28, 1),  
                  name="Conv2D_1"))  
model.add(MaxPooling2D(pool_size=(2, 2),  
                      name="Maxpooling2D_1"))  
  
model.add(Flatten(name="flatten") )  
  
# Classification part  
model.add(Dense(100, activation='relu'))  
model.add(Dense(10, activation='softmax'))
```



Partie Convolution et pooling – Extraction des feature maps

Conversion en vecteur pour entrer dans la partie MLP (input layer)

partie MLP classique pour La classification

En pratique

```
model = Sequential()  
# Convolution and pooling  
model.add(Conv2D(filters=32,  
                 kernel_size=(3, 3),  
                 activation='relu',  
                 padding="same",  
                 input_shape=(28, 28, 1),  
                 name="Conv2D_1"))  
model.add(MaxPooling2D(pool_size=(2, 2),  
                      name="Maxpooling2D_1"))  
  
model.add(Flatten(name="flatten"))  
  
# Classification part  
model.add(Dense(100, activation='relu'))  
model.add(Dense(10, activation='softmax'))
```

S'il n'y a pas d'ambiguïté le nom des variables peut être enlevé : filters, kernel_size et pool_size sont optionnels

En pratique

```
model = Sequential()  
# Convolution and pooling  
model.add(Conv2D(filters=32, ←  
            kernel_size=(3, 3),  
            activation='relu',  
            padding="same",  
            input_shape=(28, 28, 1),  
            name="Conv2D_1"))  
model.add(MaxPooling2D(pool_size=(2, 2),  
                      name="Maxpooling2D_1"))  
  
model.add(Flatten(name="flatten"))  
  
# Classification part  
model.add(Dense(100, activation='relu'))  
model.add(Dense(10, activation='softmax'))
```

Nombre de filtres.

Augmentation du nombre en fonction des niveaux car le motif devient plus complexe. Souvent des puissances de 2. (16, 32, 64, ...)



En pratique

```
model = Sequential()  
# Convolution and pooling  
model.add(Conv2D(filters=32,
```

```
    kernel_size=(3, 3),  
    activation='relu',  
    padding="same",  
    input_shape=(28, 28, 1),  
    name="Conv2D_1"))
```

```
model.add(MaxPooling2D(pool_size=(2, 2),  
                      name="Maxpooling2D_1"))
```

```
model.add(Flatten(name="flatten")) )
```

```
# Classification part
```

```
model.add(Dense(100, activation='relu'))  
model.add(Dense(10, activation='softmax'))
```

Taille du filtre



En pratique

```
model = Sequential()  
# Convolution and pooling  
model.add(Conv2D(filters=32,  
                  kernel_size=(3, 3),  
                  activation='relu',  
                  padding="same",  
                  input_shape=(28, 28, 1),  
                  name="Conv2D_1"))  
model.add(MaxPooling2D(pool_size=(2, 2),  
                      name="Maxpooling2D_1"))  
  
model.add(Flatten(name="flatten") )  
  
# Classification part  
model.add(Dense(100, activation='relu'))  
model.add(Dense(10, activation='softmax'))
```

Fonction d'activation



En pratique

```
model = Sequential()  
# Convolution and pooling  
model.add(Conv2D(filters=32,  
                  kernel_size=(3, 3),  
                  activation='relu',  
                  padding="same",  
                  input_shape=(28, 28, 1),  
                  name="Conv2D_1"))  
model.add(MaxPooling2D(pool_size=(2, 2),  
                      name="Maxpooling2D_1"))
```

```
model.add(Flatten(name="flatten")) )
```

```
# Classification part  
model.add(Dense(100, activation='relu'))  
model.add(Dense(10, activation='softmax'))
```

Keras offre deux possibilités : "*valid*" ou "*same* ».

"*valid*" signifie pas de remplissage, i.e. c'est la valeur par défaut.
"*same*" met des zéros uniformément à gauche/droite ou haut/bas de l'entrée.

Lorsque padding="*same*" et strides=1, la sortie a la même taille que l'entrée.



En pratique

```
model = Sequential()  
# Convolution and pooling  
model.add(Conv2D(filters=32,  
                  kernel_size=(3, 3),  
                  activation='relu',  
                  padding="same",  
                  input_shape=(28, 28, 1),  
                  name="Conv2D_1"))  
model.add(MaxPooling2D(pool_size=(2, 2),  
                      name="Maxpooling2D_1"))  
  
model.add(Flatten(name="flatten"))  
  
# Classification part  
model.add(Dense(100, activation='relu'))  
model.add(Dense(10, activation='softmax'))
```

Taille de l'image d'entrée : Ici 28 x 28 et il n'y a qu'un canal (1). C'est du noir et blanc. Pour couleur RGB, la valeur est 3.



En pratique

```
model = Sequential()  
# Convolution and pooling  
model.add(Conv2D(filters=32,  
                  kernel_size=(3, 3),  
                  activation='relu',  
                  padding="same",  
                  input_shape=(28, 28, 1),  
                  name="Conv2D_1"))  
  
model.add(MaxPooling2D(pool_size=(2, 2),  
                      name="Maxpooling2D_1"))  
  
model.add(Flatten(name="flatten") )  
  
# Classification part  
model.add(Dense(100, activation='relu'))  
model.add(Dense(10, activation='softmax'))
```

Pour nommer le layer.
pas du tout obligatoire
mais peut être pratique
si l'on veut accéder à une
couche par son nom plutôt
que son numéro



En pratique

```
model = Sequential()  
# Convolution and pooling  
model.add(Conv2D(filters=32,  
                  kernel_size=(3, 3),  
                  activation='relu',  
                  padding="same",  
                  input_shape=(28, 28, 1),  
                  name="Conv2D_1"))  
  
model.add(MaxPooling2D(pool_size=(2, 2),  
                      name="Maxpooling2D_1"))  
  
model.add(Flatten(name="flatten"))  
  
# Classification part  
model.add(Dense(100, activation='relu'))  
model.add(Dense(10, activation='softmax'))
```

Taille du filtre pour le pooling
Attention si aucun padding
n'est précisé (par défaut), la
valeur du padding prend celle
de pool_size.



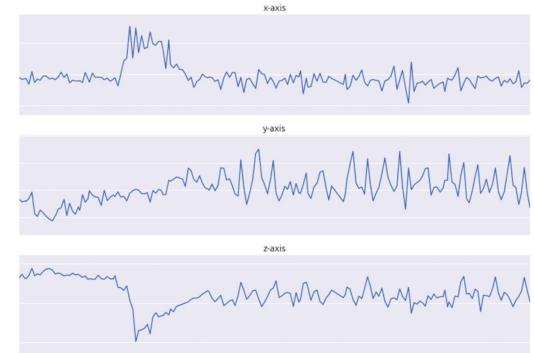
En pratique

```
model.add(Conv2D(filters=32,  
                 kernel_size=(3, 3),  
                 activation='relu',  
                 padding="same",  
dilation_rate=2,  
                 input_shape=(28, 28, 1),  
                 name="Conv2D_1"))
```

Taux de dilatation.
Si dilatation = 1, on prend chaque 1er élément (pas de trous).
Si dilatation = 2, on prend tous les 2 (écart de taille 1). Etc.

Les convolutions 1D

- Séries temporelles, textes



```
from keras.layers import Conv1D
```

```
model = Sequential()
```

```
model.add(Conv1D(1, kernel_size=5, input_shape = (120, 3)))
```



Le noyau est un vecteur

Les convolutions 3D

- Images 3D (IRM), Vidéos, images satellites

```
from keras.layers import Conv3D
```

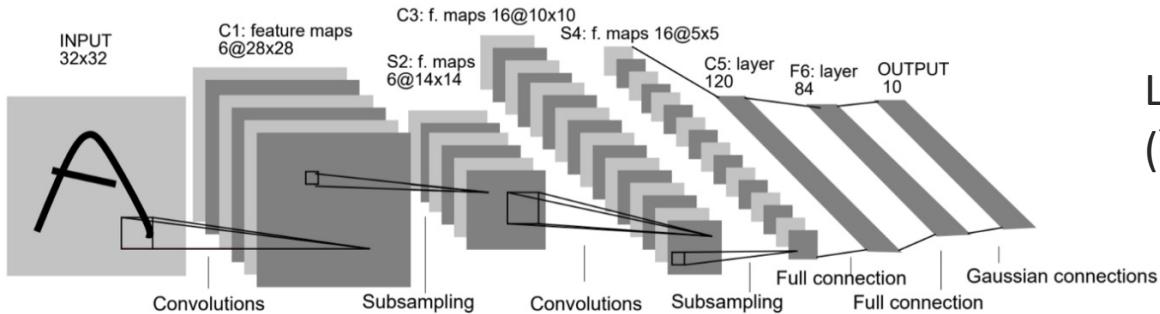
```
model = Sequential()
```

```
model.add(Conv3D(1, kernel_size=(3,3,3), input_shape = (128, 128, 128, 3)))
```

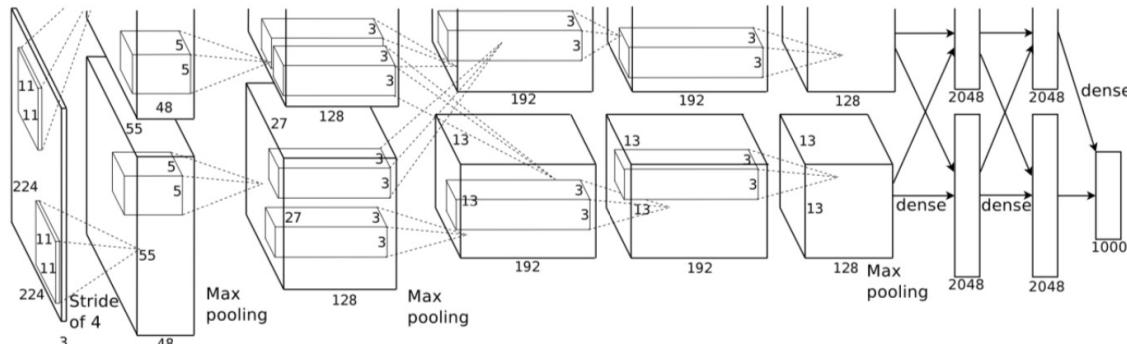


Le noyau est en 3D vecteur

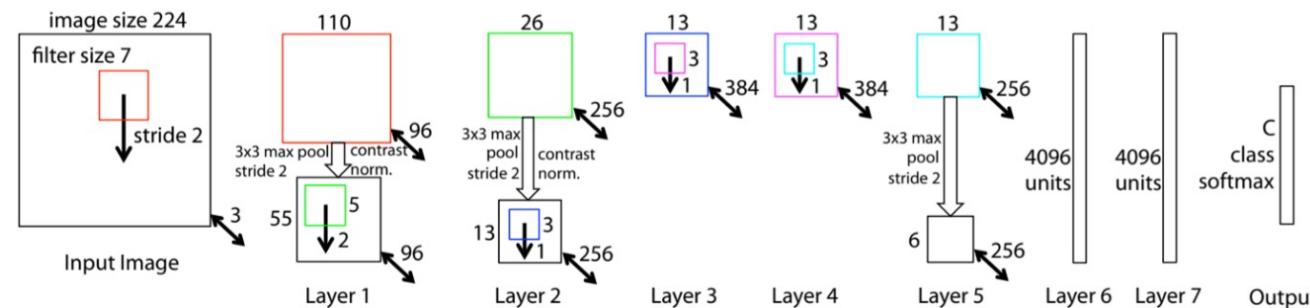
Des architectures en constante évolution



LeNet-5 - 1998
(Yann Le Cun Facebook)

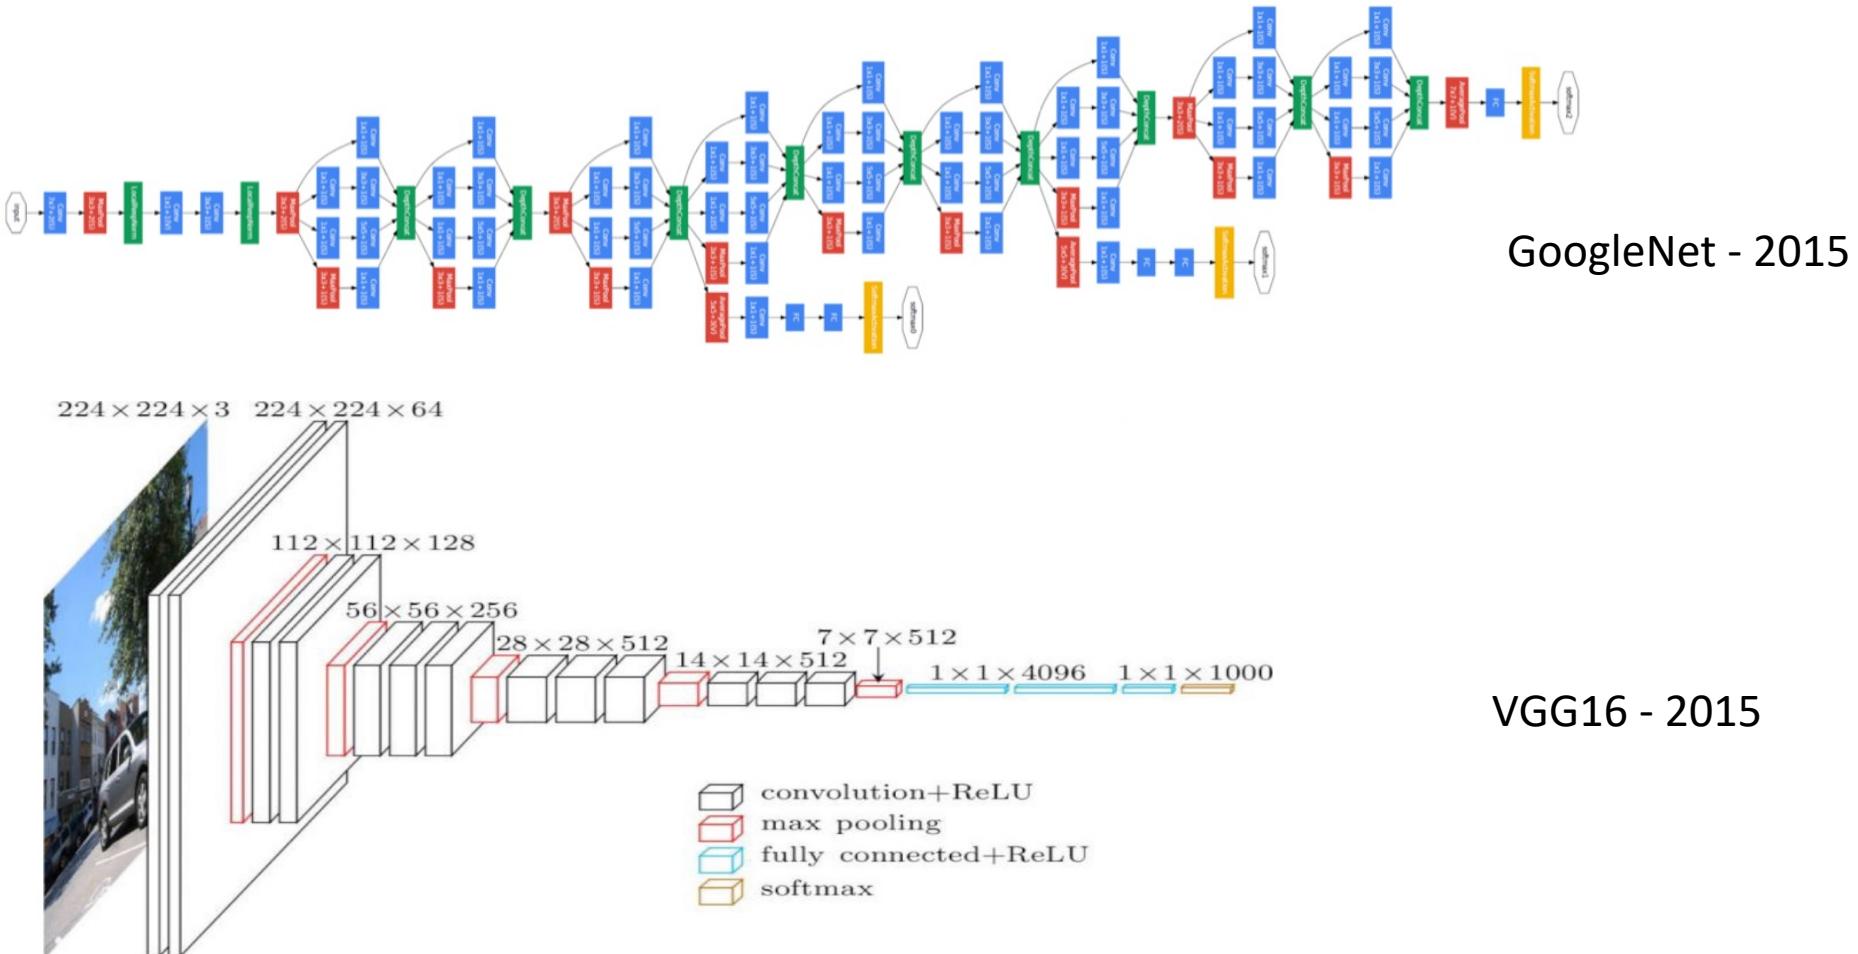


AlexNet - 2012

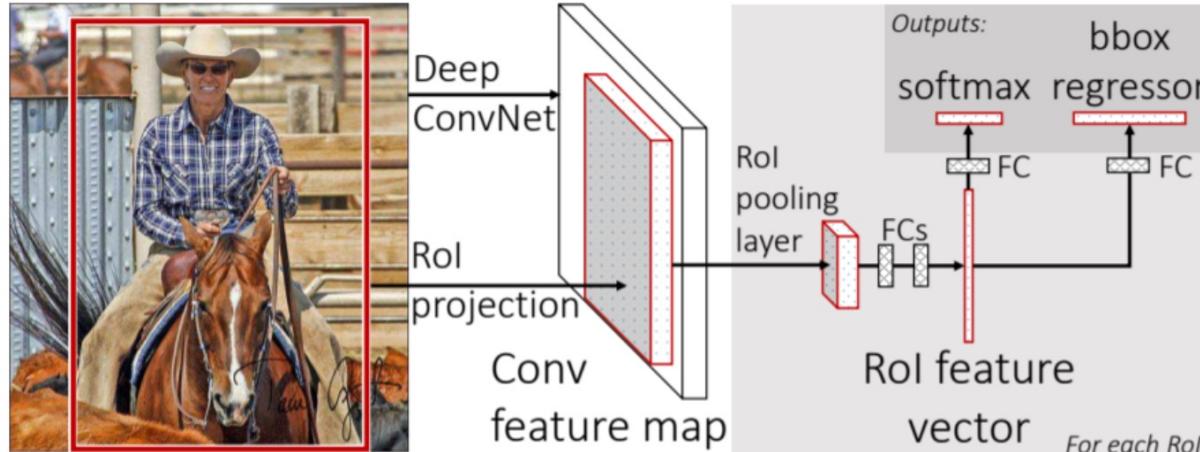


Zfnet - 2013

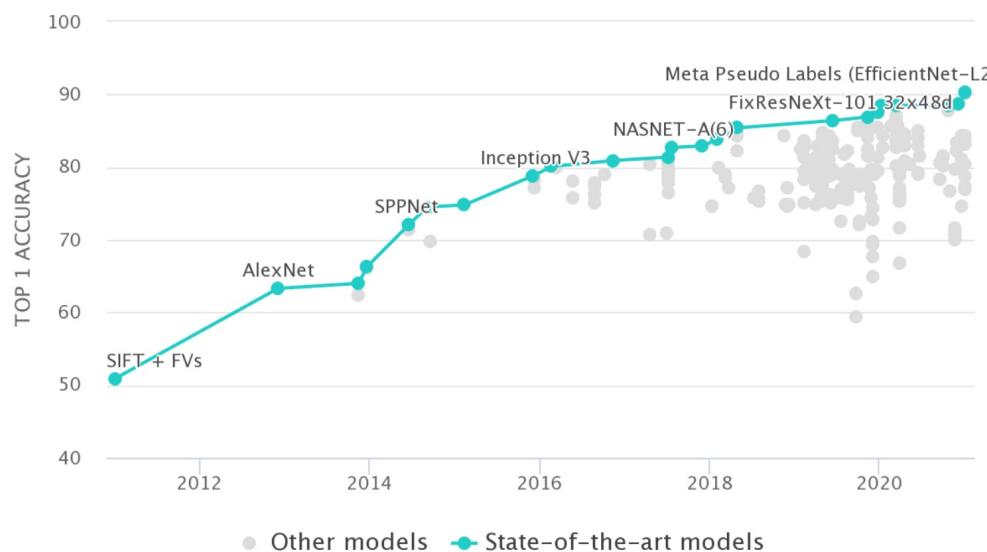
Des architectures en constante évolution



Des architectures en constante évolution



Fast R-CNN - 2015

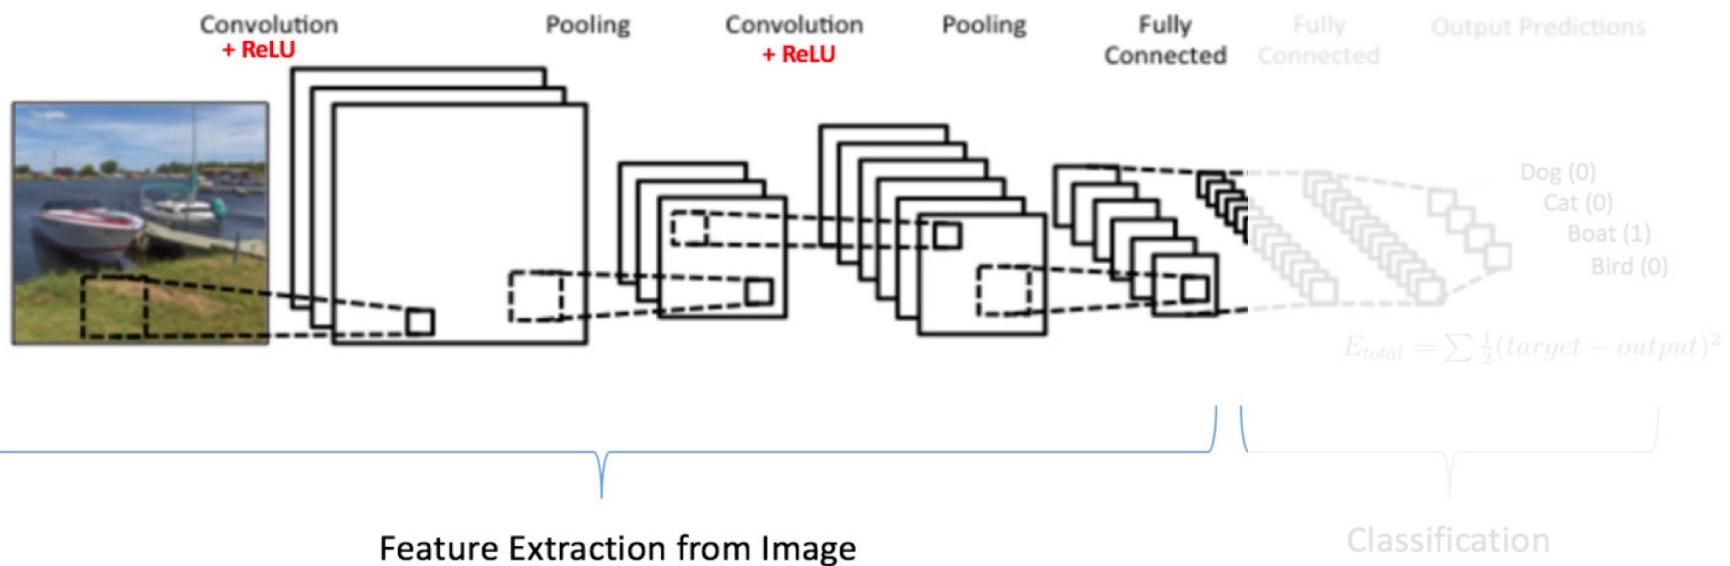


Source : AI summer

Transfer learning

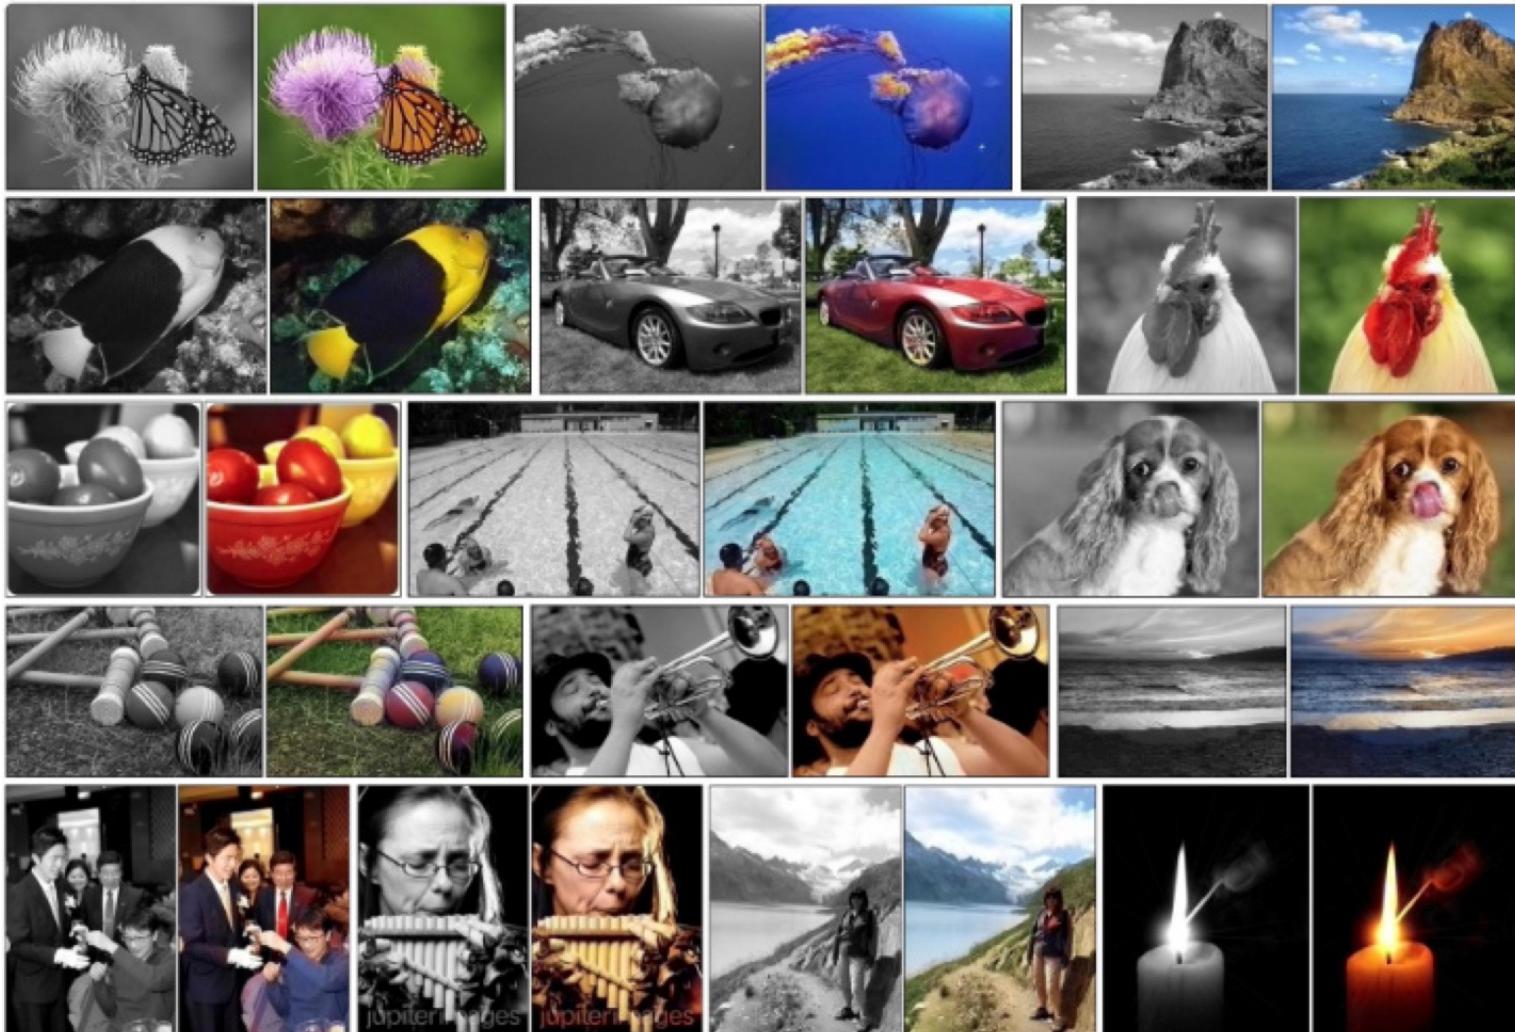
- Profiter des modèles déjà appris sur des milliards de données (le poids/les valeurs des filtres ont été appris) pour améliorer le modèle
 - Il faut faire attention à la taille des images !
 - Il faut rendre les du modèle transféré comme « non apprenable »
 - Il faut enlever partie classification du modèle transféré et la remplacer par sa propre partie (les sorties attendues ne sont généralement pas les mêmes – softmax vs sigmoid – nombre de classes)

Une base pour pleins d'applications



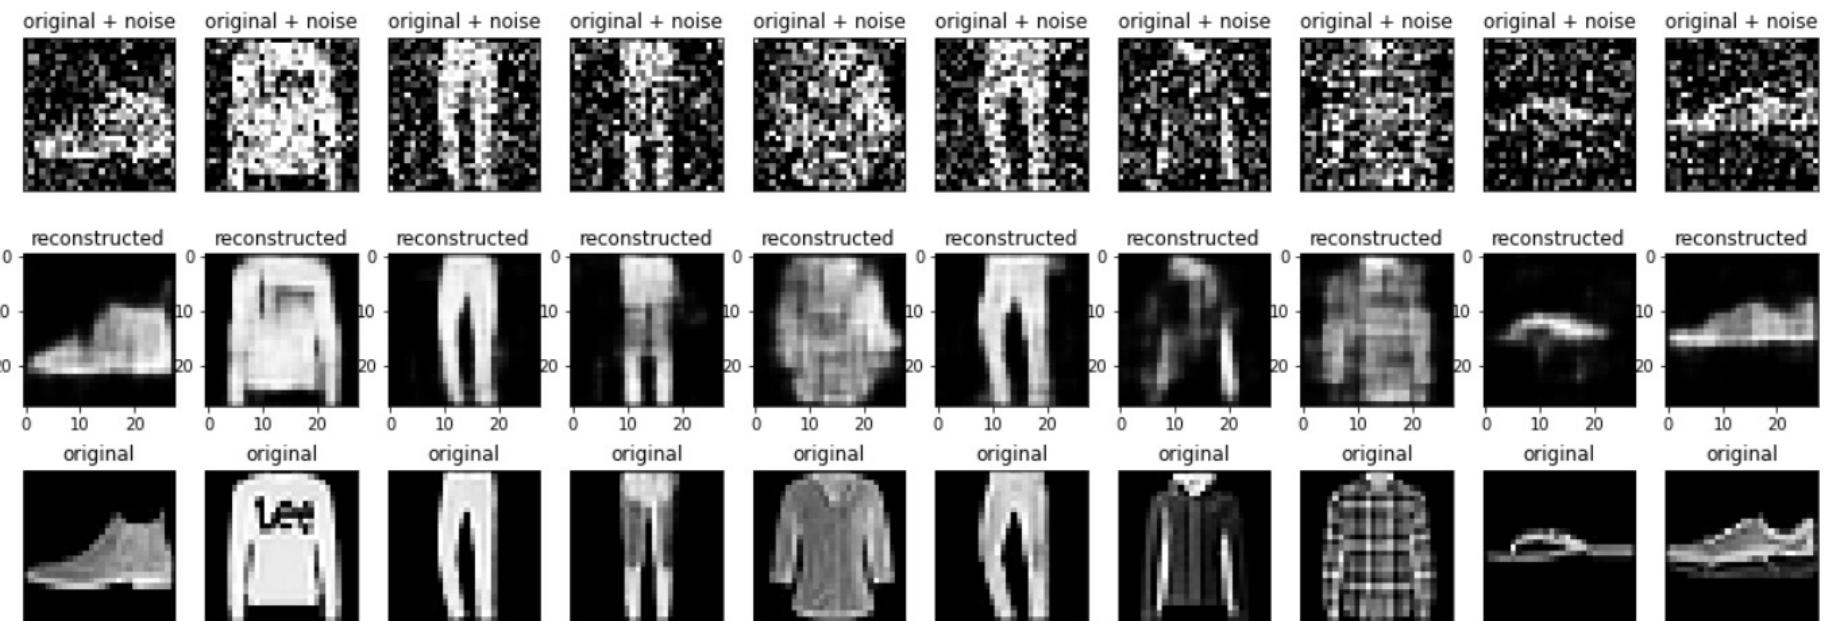
Segmentation
Détection
Correction

Colorisation

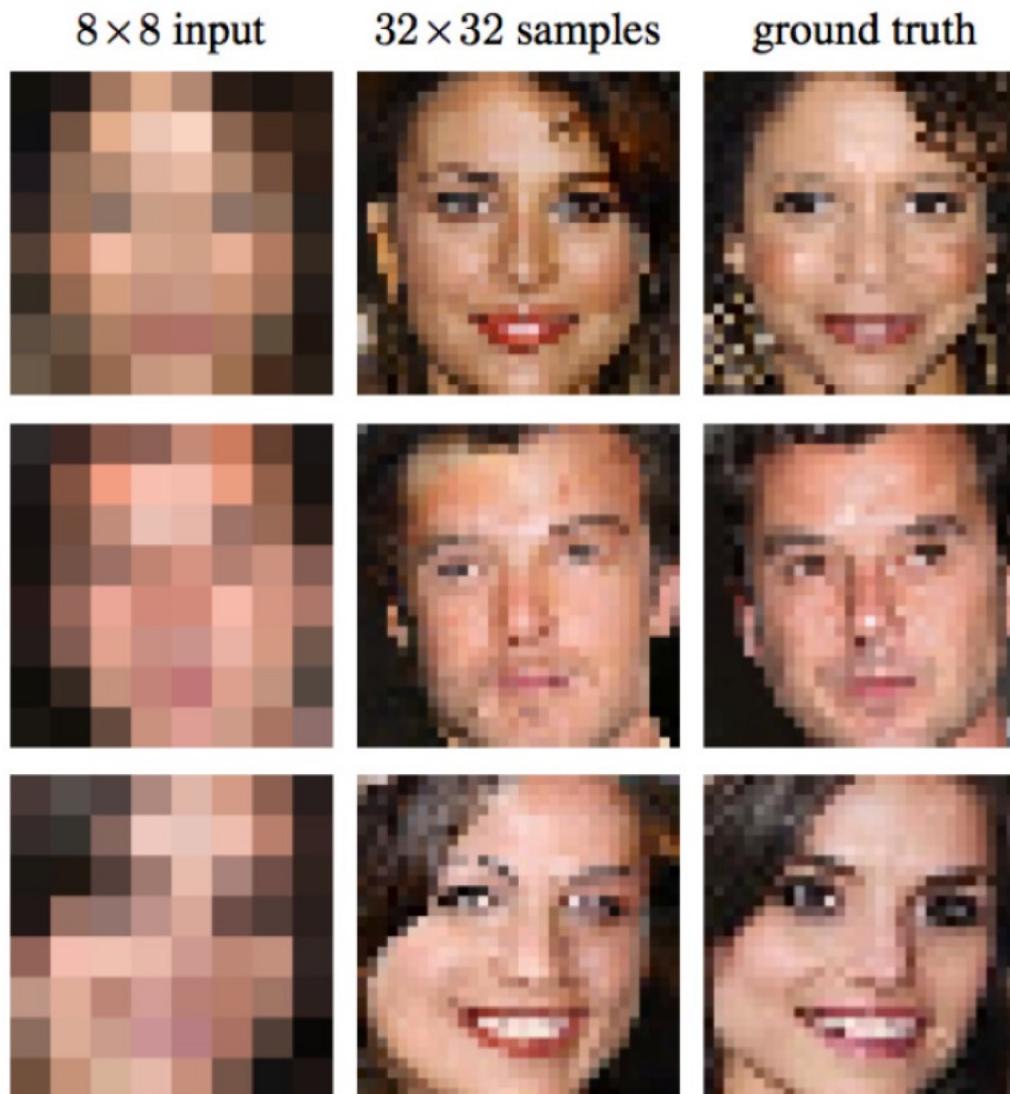


Source : MIT

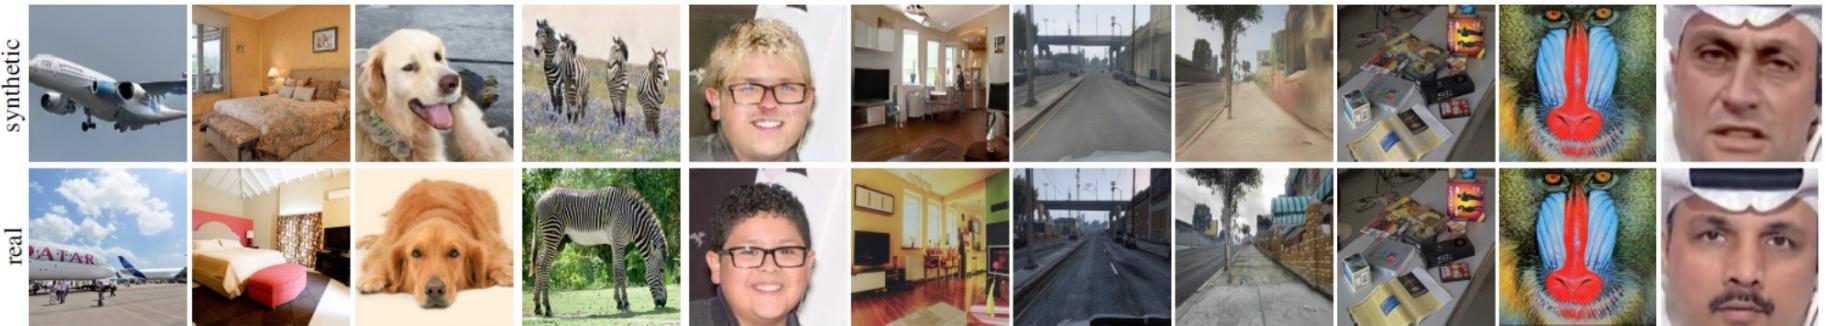
Enlever le bruit



Augmenter la qualité de l'image



Générer des images

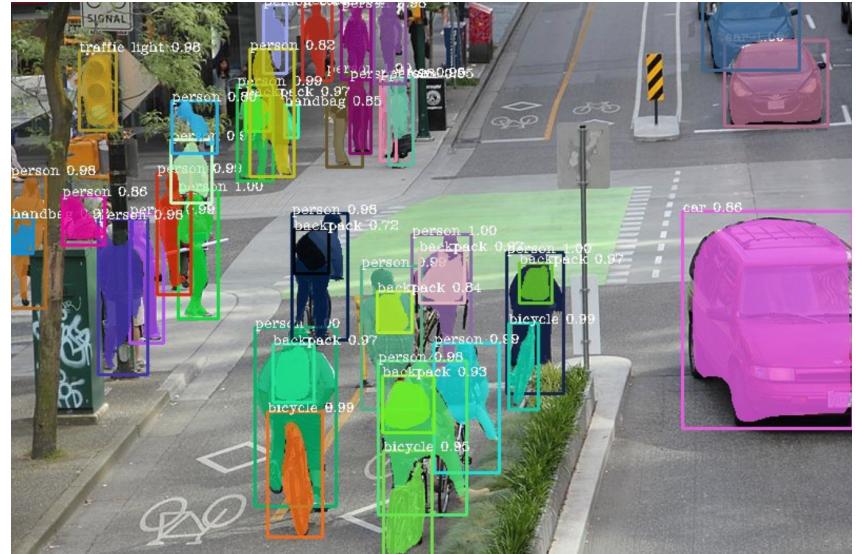


CNN-generated images are surprisingly easy to spot...for now
<https://peterwang512.github.io/CNNDetection/>

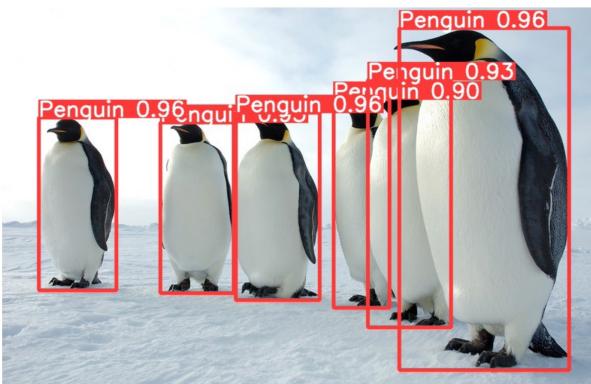


<https://generated.photos/face-generator/new>

Segmentation d'images

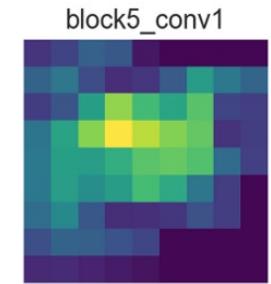
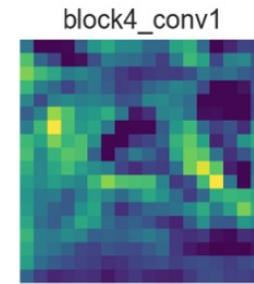
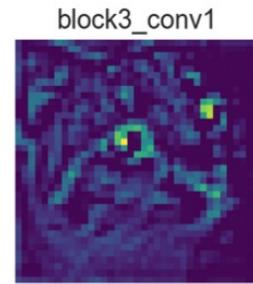
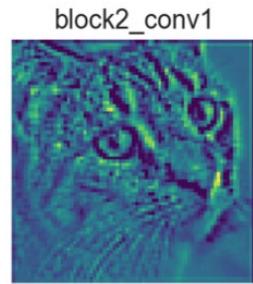
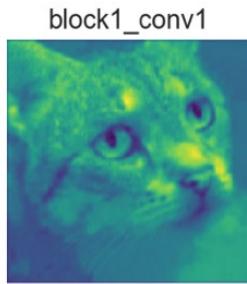


PIXELLIB - <https://towardsdatascience.com/image-segmentation-with-six-lines-of-code-acb870a462e8>



Yolo –

<https://towardsdatascience.com/the-practical-guide-for-object-detection-with-yolov5-algorithm-74c04aac4843>



- Des questions ?