



# VUES LOGIQUE / GRAPHE

## DES FAITS ET DES REQUÊTES CONJONCTIVES

HAI933I

# RAPPELS : BASES DE FAITS ET REQUÊTES CONJONCTIVES

- Une **base de faits F** est généralement vue comme un ensemble d'atomes instanciés (« ground »)
- D'un point de vue logique, **F** est vue comme la conjonction de ces atomes
- On peut étendre la notion de base de faits pour prendre en compte des **valeurs inconnues** : **variables** quantifiées existentiellement  
=> une base de faits est alors vue comme une **conjonction d'atomes dont toutes les variables sont quantifiées existentiellement**

## BD relationnelle

Movie		Actor		Play	
m_id		a_id		m_id	a_id
m1	...	a	...	a	m1
m2	...	b	...	a	m2
?x	...	c	...	c	?x

## Base de faits

{ movie(m1), movie(m2), movie(**x**),  
actor(a), actor(b), actor(c), play(a,m1),  
play(a,m2), play(c,**x**) }

## Formule logique associée à une base de faits

$\exists x ( \text{movie}(m1) \wedge \text{movie}(m2) \wedge \text{movie}(\mathbf{x})$   
 $\wedge \text{actor}(a) \wedge \text{actor}(b) \wedge \text{actor}(c)$   
 $\wedge \text{play}(a,m1) \wedge \text{play}(a,m2) \wedge \text{play}(c,\mathbf{x}) )$

# RAPPELS : BASES DE FAITS ET REQUÊTES CONJONCTIVES

---

Une **requête conjonctive (CQ)**  $Q(x_1 \dots x_k)$  est de la forme

$$\exists x_{k+1}, \dots, x_m (A_1 \wedge \dots \wedge A_p)$$

où  $A_1, \dots, A_p$  sont des atomes ayant pour variables  $x_1, \dots, x_m$

Autrement dit, une requête conjonctive est une **conjonction d'atomes quantifiée existentiellement** (mais pas forcément close)

Notation simplifiée  $Q(x_1 \dots x_k) = \{ A_1, \dots, A_p \}$

$$q(x) = \exists y (movie(y) \wedge play(x, y))$$

$$q(x) = \{ movie(y), play(x, y) \}$$

## FRAGMENT EXISTENTIEL CONJONCTIF POSITIF : $\text{FOL}(\exists, \wedge)$

Formules construites avec le quantificateur existentiel ( $\exists$ ) et la conjonction ( $\wedge$ )

- Forme normalisée (« prénexe ») :

$\exists x_1 \dots \exists x_n (A_1 \wedge \dots \wedge A_p)$  où les  $A_i$  sont des atomes  
et chaque  $x_j$  apparaît dans un  $A_i$

- Permettent de représenter des bases de faits (et bases de données relationnelles) et des requêtes conjonctives
- Pour des formules closes (bases de faits et CQs booléennes) :


$f1 \models f2$  ssi il existe un homomorphisme de  $f2$  dans  $f1$

Dans ce cours :

- Vision « graphe » de ces formules ( $\Rightarrow$  homomorphisme de graphe)
- Notion de minimalité : peut-on supprimer des atomes en gardant une formule équivalente ? Deux formules équivalentes sont-elles « identiques » ?

- On note  $G = (V, E)$  un **graphe orienté** où  $V$  est l'ensemble des sommets (*vertices*) et  $E$  est l'ensemble des arcs (*edges*)
- Un ensemble d'atomes avec **un seul prédicat binaire** et **sans constantes** peut être vu comme un graphe orienté

$\{ p(x,y), p(y,z), p(z,x), p(y,y) \}$



(et réciproquement pour les graphes sans sommets isolés – ou alors on introduit un prédicat unaire pour typer les sommets)

Etant donné un tel ensemble d'atomes  $A$ , on construit un graphe  $(V, E)$  tel que :

- $V$  est en bijection avec les termes de  $A$  (des variables ici) (soit  $b$  cette bijection)
- $E$  est en bijection avec les atomes de  $A$  :

$E$  contient un arc  $(b(x), b(y))$  si et seulement si  $p(x,y) \in A$

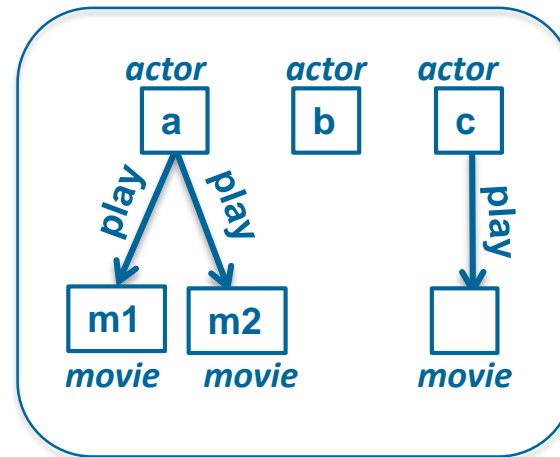
- On étiquette :

les arcs si on a plusieurs prédicats binaires

les sommets si on a des constantes

- On peut ajouter un 2<sup>ème</sup> type d'étiquette sur les sommets pour représenter les prédicats unaires


movie(m1), movie(m2), movie(x),  
actor(a), actor(b), actor(c),  
play(a,m1), play(a,m2), play(c,x)



Et si on a des prédicats  
d'arité supérieure à 2 ?

# ENSEMBLE D'ATOMES ENCODÉ PAR UN GRAPHE

- À un ensemble d'atomes, on associe naturellement un **hypergraphe « orienté »**.  
La notion d'**hyperarc** généralise la notion d'arc : n-uplet ( $n > 0$ ) de sommets
- Il est pratique de considérer le **graphe d'incidence associé** à l'hypergraphe.  
C'est un **multi-graphe biparti non-orienté**
  - « biparti » : l'ensemble des sommets est partitionné en 2 classes, tel qu'il n'y a aucun arc entre 2 sommets de la même classe
  - « multi-graphe » : il peut y avoir plusieurs arêtes entre deux sommets



- 1 **sommet** par **terme**  
étiqueté par le terme si c'est une constante
- 1 **sommet** par **atome**  
étiqueté par le prédicat de l'atome
- les **arêtes** lient chaque sommet atome aux sommets termes qui représentent ses arguments
- les arêtes incidentes à un sommet atome sont totalement ordonnées (ce qu'on peut représenter par une numérotation)

## PLUS PRÉCISÉMENT :

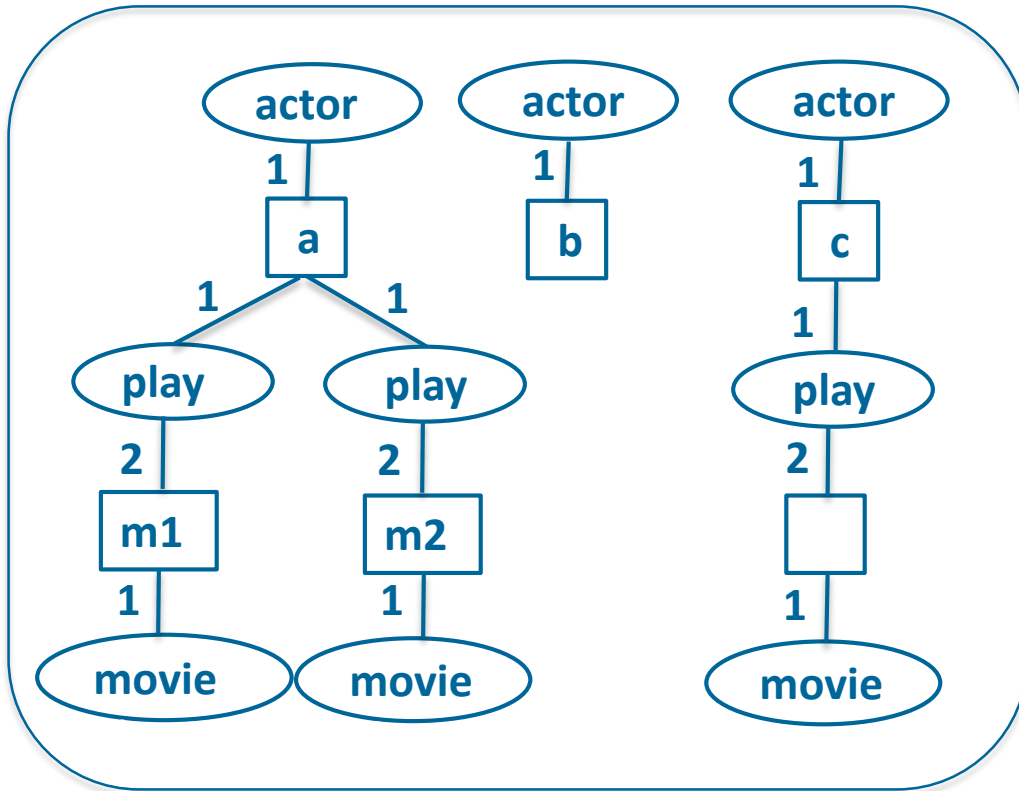
---

À un ensemble d'atomes  $F$ , on associe un (multi-)graphe biparti  $(V_T, V_A, E, \text{label})$  tel que :


- $V_T$  : ensemble des sommets termes  
(on a une bijection  $b_T$  de l'ensemble des termes de  $F$  vers  $V_T$ )
- $V_A$  : ensemble des sommets atomes  
(on a une bijection  $b_A$  de l'ensemble des atomes de  $F$  vers  $V_A$ )
- $E$  : multi-ensemble des arêtes : pour chaque atome  $A = p(t_1, \dots, t_k)$  de  $F$ ,  
on a  $k$  arêtes entre  $b_A(A)$  et chacun des  $b_T(t_i)$
- **label** : fonction d'étiquetage qui vérifie :
  - tout **sommet terme**  $b_T(t)$  est étiqueté par  $t$  si  $t$  est une constante, sinon il n'est pas étiqueté
  - tout **sommet atome**  $b_A(A)$  avec  $A = p(t_1, \dots, t_k)$  est étiqueté par  $p$   
et toute arête  $(b_A(A), b_T(t_i))$  est étiquetée par  $i$



movie(m1), movie(m2), actor(a), actor(b), actor(c),  
 play(a,m1), play(a,m2), movie(x), play(c,x)



graphe biparti associé à la vision « hypergraphe »







graphe plus simple  
 (car prédicats d'arité  $\leq 2$ )


# GRAPH HOMOMORPHISMS (1)

- Let  $G_1=(V_1,E_1)$  to  $G_2=(V_2,E_2)$  be classical graphs.

**Homomorphism**  $h$  from  $G_1$  to  $G_2$ : mapping from  $V_1$  to  $V_2$  s. t.  
for every edge  $(u,v)$  in  $E_1$ ,  $(h(u),h(v))$  is in  $E_2$



*Find the homomorphisms between these graphs*



Here,  $F \geq G$  means

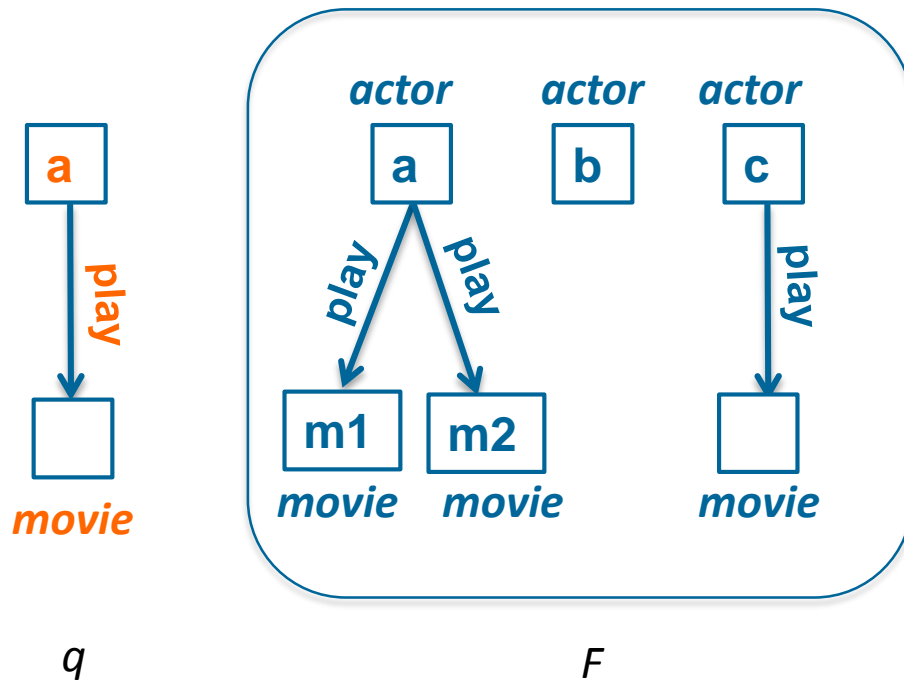
«  $F$  maps to  $G$  by homomorphism »

# GRAPH HOMOMORPHISMS (2)

- Let  $G_1=(V_1,E_1)$  to  $G_2=(V_2,E_2)$  be classical graphs.

**Homomorphism**  $h$  from  $G_1$  to  $G_2$ : mapping from  $V_1$  to  $V_2$  s. t.  
for every edge  $(u,v)$  in  $E_1$ ,  $(h(u),h(v))$  is in  $E_2$

- If there are labels: they have to be “kept” as well

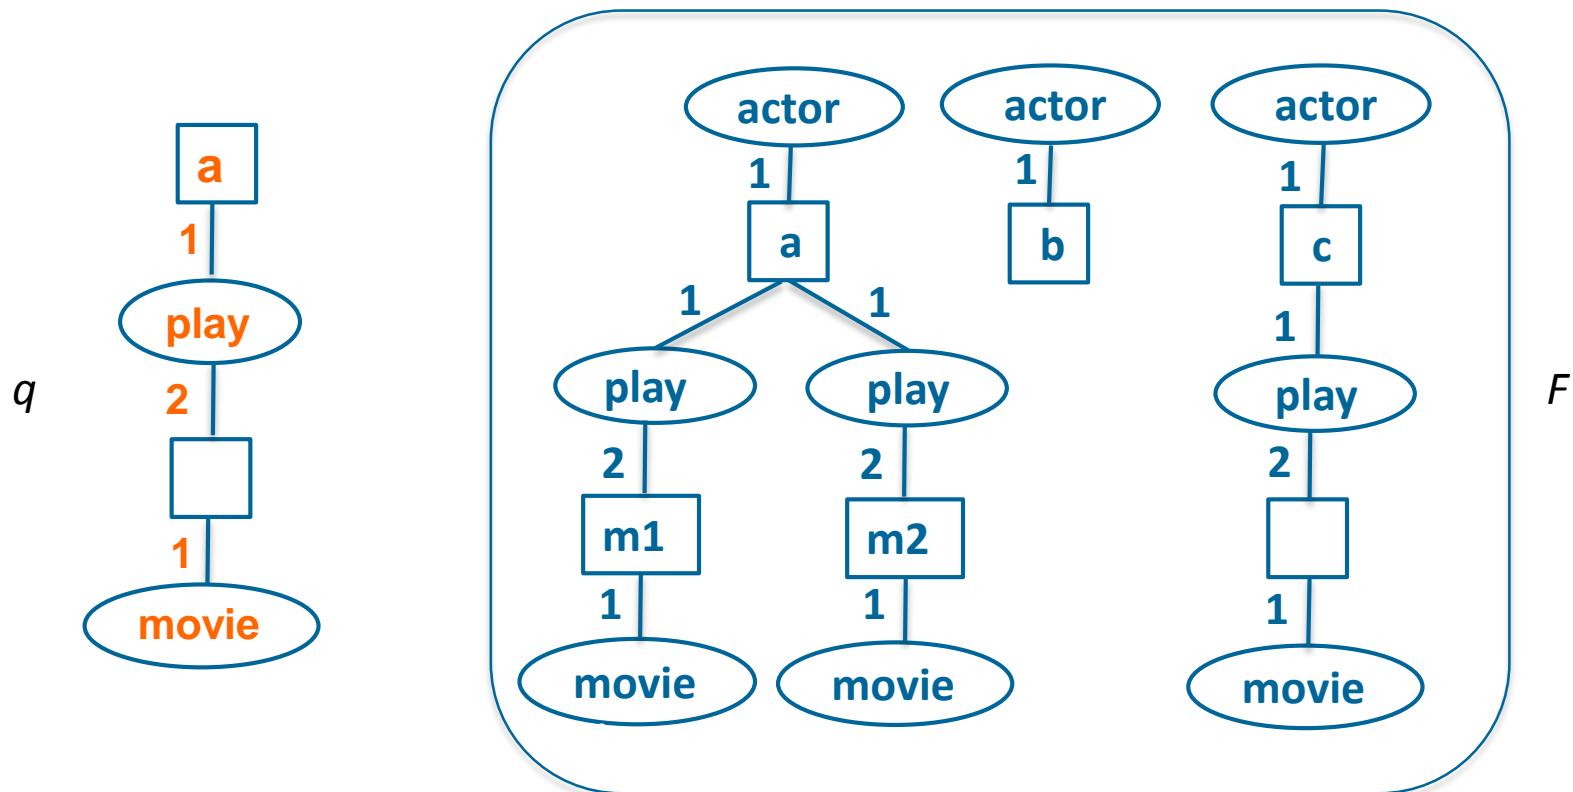


# GRAPH HOMOMORPHISMS (3)

- Let  $G_1=(V_1,E_1)$  to  $G_2=(V_2,E_2)$  be classical graphs.

**Homomorphism**  $h$  from  $G_1$  to  $G_2$ : mapping from  $V_1$  to  $V_2$  s. t.  
for every edge  $(u,v)$  in  $E_1$ ,  $(h(u),h(v))$  is in  $E_2$


- If there are labels: they have to be “kept” as well



# HOMOMORPHISMS ON GRAPHS ASSOCIATED WITH ATOM SETS

- Let *graph* be the translation from a set of atoms to a bipartite (multi-)graph
- Let  $F_1$  and  $F_2$  be two sets of atoms, and:  
 $G_1 = \text{graph}(F_1) = (V_{T1}, V_{A1}, E_1, \text{label}_1)$   
 $G_2 = \text{graph}(F_2) = (V_{T2}, V_{A2}, E_2, \text{label}_2)$
- A **homomorphism from  $G_1$  to  $G_2$**  is a mapping  $h$  from  $V_{T1} \cup V_{A1}$  to  $V_{T2} \cup V_{A2}$  such that:
  - for all  $v \in V_{T1}$ ,  $h(v) \in V_{T2}$  ; and for all  $v \in V_{A1}$ ,  $h(v) \in V_{A2}$
  - for all  $v \in V_{T1} \cup V_{A1}$  ,  $\text{label}(h(v)) = \text{label}(v)$  [when  $\text{label}(v)$  is defined]
  - for all  $e = (a,t) \in E_1$ ,  $h(e) = (h(a),h(t)) \in E_2$ , and  $\text{label}(e) = \text{label}(h(e))$
- Reminder: a **homomorphism from  $F_1$  to  $F_2$**  is a mapping  $h$  from  $\text{variables}(F_1)$  to  $\text{terms}(F_2)$  such that: for all  $p(t_1, \dots, t_k) \in F_1$ ,  $h(p(t_1, \dots, t_k)) \in F_2$   
[ where  $h(p(t_1, \dots, t_k)) = p(h(t_1), \dots, h(t_k))$  ]

**There is a homomorphism from  $F_1$  to  $F_2$   
if and only if  
there is a [graph] homomorphism from  $\text{graph}(F_1)$  to  $\text{graph}(F_2)$**



Here,  $F \geq G$  means «  $F$  maps to  $G$  by homomorphism »

If  $F$  maps to  $G$  and  $G$  maps to  $F$ , we say that they are **homomorphically equivalent**  
 This notion exactly corresponds to **logical equivalence**

# ISOMORPHISM OF SETS OF ATOMS / GRAPHS

- Let  $f$  and  $g$  be sets of atoms

**Isomorphism**  $h$  from  $f$  to  $g$ : **bijjective** mapping from  $variables(f)$  to  $variables(g)$   
such that  $h(f) = g$

When  $f$  and  $g$  are isomorphic :

we also say that  $f$  and  $g$  are “equal up to a bijective variable renaming”

- Let  $G_1=(V_1,E_1)$  to  $G_2=(V_2,E_2)$  be classical graphs

**Isomorphism**  $h$  from  $G_1$  to  $G_2$  : **bijjective** mapping from  $V_1$  to  $V_2$   
such that for all vertices  $u,v$  in  $V_1$ ,  
 $(u,v) \in E_1$  if and only if  $(h(u),h(v)) \in E_2$

If the graphs are labeled:

$label(u) = label(h(u))$  for all  $u \in V_1$

$label((u,v)) = label(h(u),h(v))$  for all  $(u,v) \in E_1$


It may happen that  $f$  and  $g$  are equivalent *but not* isomorphic

Intuitively, it means that at least one of them contains « redundant » information



# REMOVING REDUNDANCIES: GETTING TO THE *CORE*

- A **core** is a set of atoms that is **not equivalent** to any of its **strict** subsets (i.e., it does not map by homomorphism to one of its strict subsets).
- Given  $f$  a (finite) set of atoms, the **core of  $f$**  is a minimal subset of  $f$  equivalent to  $f$ . It may happen that  $f$  has several cores, but they are **all isomorphic**. Hence, we can say « the » core of  $f$ .
- If  $f$  and  $g$  are **equivalent**, the core of  $f$  is **isomorphic** to the core of  $g$ .



Exercise : find an algorithm to **compute the core** of an atom set

# CONCLUSION

---

- Le **fragment logique existentiel conjonctif** est fortement lié aux **(hyper)graphes** (donc aux modèles de données graphes, comme RDF)
- Les notions d'*homomorphisme* et de *core* sont fondamentales pour de nombreux problèmes sur les bases de faits et les requêtes

Par exemple : **optimisation de requêtes** conjonctives

- Déterminer si deux requêtes sont équivalentes
  - but : exécuter la plus simple pour le SGBD
- Minimiser une requête : supprimer toutes ses redondances
  - but : accélérer l'évaluation de la requête
- Déterminer si une requête  $Q_1$  est plus spécifique qu'une requête  $Q_2$ 
  - but : accélérer l'évaluation de  $Q_1$  (connaissant les réponses à  $Q_2$ )

[ On parle de problèmes d'optimisation « **statique** » de requêtes, au sens où ils sont indépendants d'une base de données (ou base de faits) particulière ]